İSTATİSTİK II

SINAV ÇALIŞMA NOTU

Asimetri-Basıklık • Bağımlı-Bağımsız Örnekler • ANOVA • Regresyon-Korelasyon

İÇİNDEKİLER

1. Asimetri-Çarpıklık Ölçüleri
2. Basıklık-Kurtosis Ölçüsü
3. Oranlar
4. İki Anakütle Arasındaki Farkın Testleri (Bağımsız Örnekler)
5. İki Anakütle Arasındaki Farkın Testleri (Bağımlı Örnekler)
6. ANOVA – Tek Yönlü Varyans Analizi
7. Regresyon ve Korelasyon Analizi

1. ASİMETRİ-ÇARPIKLIK ÖLÇÜLERİ

Serilerdeki birimlerin hangi değerlerde toplandığını gösteren ölçülere "Asimetri-Çarpıklık Ölçüleri" (Measures of Skewness) adı verilmektedir. Bilindiği gibi ortalamalar, serilerdeki birimleri tek bir değerle tanımlayan, dağılma ölçüleri de bu ortalama değerden birimlerin ne kadar farklılık gösterdiğini ortaya çıkaran ölçülerdir.

Asimetri ölçüleri ortalamalara ve dağılma ölçülerine ek olarak birimlerin hangi değerlerde toplandığını göstererek birimler hakkında bu iki ölçünün verdiği bilgilere önemli bir katkıda bulunmaktadır. Ortalama ve dağılma ölçüleriyle birlikte üçüncü istatistik ölçü olarak birimler hakkında çok önemli bilgilerin ortaya çıkarılmasına imkân vermektedir.

Asimetri üç yöntemle saptanmaktadır:

- Ortalamalara dayanan asimetri ölçüsü
- Kartillere dayanan asimetri ölçüsü
- Momentlere dayanan asimetri ölçüsü

1.1. Ortalamalara Dayanan Asimetri Ölçüsü (Pearson)

"Pearson asimetri ölçüsü" adı altında da geçen bu ölçü, iki ortalama -aritmetik ortalama ve mod (veya medyan)- ile standart sapma yardımıyla elde edilmektedir.

Anakütle verileriyle:

$$\mathbf{As = (\bar{X} - Mod) / \sigma}$$

Örnek verileriyle:

$$\mathbf{As = (\bar{X} - Mod) / s}$$

Hafif asimetrik serilerde $Mod = \bar{X} - 3(\bar{X} - Med)$ olduğu için Pearson asimetri ölçüsü:

$$\mathbf{As = 3(\bar{X} - Med) / \sigma}$$

Simetri ve Çarpıklık Durumları

Simetrik serilerde $\bar{X} = Mod = Medyan$'dır. Asimetri sıfırdır.

Seri sağa çarpık ise aritmetik ortalama mod ve medyandan büyük olduğu için asimetri pozitiftir. Sola çarpık serilerde ise aritmetik ortalama mod ve medyandan küçük olduğu için asimetri negatif olacaktır.

Farkın $(\bar{X} - Mod)$ pozitif olması serinin sağa çarpık, negatif olması ise sola çarpık olduğunu göstermektedir. Farkın sıfıra yakın olması serinin simetrik veya hafif asimetrik olduğunun kanıtıdır.

Yorumlama:

- $|As| \approx 0 \rightarrow$ Simetrik veya hafif asimetrik
- $|As| < 0{,}5 \rightarrow$ Önemsiz (hafif) asimetri
- $0{,}5 \leq |As| < 1 \rightarrow$ Orta şiddette asimetri
- $|As| \geq 1 \rightarrow$ Kuvvetli asimetri

• Teorik olarak Pearson asimetri ölçüsünün ±3 arasında değişmesi gerekmektedir. Ancak çok nadir durumlarda ölçünün ±1 sınırlarını aştığı görülmüştür.

İki ortalama arasındaki farkın standart sapmaya bölünmesindeki neden ise farklı cins ve büyüklükteki değerlere sahip birimlerden oluşan serilerin karşılaştırılabilmesini sağlamaktır. Böylece farklı dağılması olan seriler karşılaştırılabilir duruma gelmektedir.

Pearson asimetri ölçüsü aritmetik ortalama, mod ve standart sapmanın uygulanabildiği serilerde asimetri ölçüsü olarak kullanılmaktadır. Özellikle açık sınıflı gruplanmış serilerde aritmetik ortalama ve standart sapma hesaplanamadığı için kullanılması mümkün değildir.

Pearson asimetri ölçüsünün hassasiyeti, hesaplanmasında kullanılan üç tanımsal istatistik ölçüden ($\bar{X}$, Mod ve σ) modun serideki tüm değerlere dayanan bir ölçü olmaması nedeniyle önemli ölçüde azalmaktadır.

ÖRNEK: Pearson Asimetri Hesabı

Fiyat Serisi: $\bar{X} = 11,3$; $\sigma = 0,663$; $Med = 11,2$

As = 3($\bar{X}$ − Med) / σ = 3(11,3 − 11,2) / 0,663 = 0,3 / 0,663 = 0,452

→ Orta derecede pozitif (sağa çarpık)

Eğitim Serisi: $\bar{X} = 7$; $\sigma = 1,18$; $Mod = 8$

As = ($\bar{X}$ − Mod) / σ = (7 − 8) / 1,18 = −0,847

→ Önemli (orta-kuvvetli) negatif asimetri (sola çarpık) — eğitim düzeyi yüksek olanlar çoğunlukta

Ücret Serisi: $\bar{X} = 158$; $\sigma = 4,613$; $Mod \cong 159,57$

Mod hesabı: Mod ≅ 158 + (9/(9+14)) × 4 = 158 + 1,57 = 159,57

As = (158 − 159,57) / 4,613 = −0,340

→ Daha önemsiz negatif asimetri

Pearson asimetri ölçüsüne göre fiyat serisi orta derecede pozitif (0,452), eğitim serisi önemli (−0,847), ücret serisi ise daha önemsiz (−0,339) negatif asimetrisi olan serilerdir.

1.2. Momentlere Dayanan Asimetri Ölçüsü (α_3)

$\mu_3 = \Sigma(X_i - \bar{X})^3 / N$ (basit seri)

$\mu_3 = \Sigma f_i(X_i - \bar{X})^3 / \Sigma f_i$ (frekans serisi)

$\alpha_3 = \mu_3 / \sigma^3$

- **$\alpha_3 > 0$ → Sağa çarpık | $\alpha_3 < 0$ → Sola çarpık | $\alpha_3 = 0$ → Simetrik**

ÖRNEK: Basit Seri (Fiyat)

X_i: 10,5 / 10,8 / 11,2 / 11,6 / 12,4 → $\bar{X} = 11,3$ $\sigma = 0,663$

X_i	$(X_i - \bar{X})$	$(X_i - \bar{X})^2$	$(X_i - \bar{X})^3$	$(X_i - \bar{X})^4$
10,5	−0,8	0,64	−0,512	0,4096
10,8	−0,5	0,25	−0,125	0,0625
11,2	−0,1	0,01	−0,001	0,0001
11,6	0,3	0,09	0,027	0,0081
12,4	1,1	1,21	1,331	1,4641
Σ=56,5	0,0	2,20	0,720	1,9444

μ_3 = 0,720 / 5 = 0,144

$\alpha_3 = \mu_3 / \sigma^3$ = 0,144 / 0,29 = 0,497

→ Orta derecede sağa çarpık

ÖRNEK: Gruplanmamış Seri (Eğitim)

$\bar{X} = 7$, $\sigma = 1,18$

X_i	f_i	$(X_i - \bar{X})$	$f_i(X_i - \bar{X})^2$	$f_i(X_i - \bar{X})^3$	$f_i(X_i - \bar{X})^4$
5	6	−2	24	−48	96
6	12	−1	12	−12	12
7	13	0	0	0	0

8	14	1	14	14	14
9	5	2	20	40	80
Σ	50			−6	202

$\mu_3 = -6 / 50 = -0{,}12$

$\alpha_3 = -0{,}12 / 1{,}64 = -0{,}073$

→ Simetriğe çok yakın (Pearson ölçüsüyle yüksek ve negatif gözüken bu serinin daha hassas ölçü olan α_3 ile simetriğe yakın olduğu anlaşılmaktadır.)

2. BASIKLIK-KURTOSİS ÖLÇÜSÜ

"Basıklık Ölçüleri (Coefficients of Kurtosis)" serideki birimlerin dağılımının basık (platykurtic), sivri (leptokurtic) veya normal (mesokurtic) olup olmadığının ortaya çıkarılmasında kullanılmaktadır. Genellikle herhangi bir dağılımın normal dağılıma oranla ne durumda olduğunun araştırılmasında önem kazanmaktadır.

Basıklık ölçülerinin amacı, serilerin her iki uçtaki değerler arasındaki dağılma oranla merkezi değere (ortalama) yakın değerlerde nasıl toplanma olduğunu saptamaktır. Sivri serilerde merkezi ölçüler etrafında birimlerin toplandığı, basık serilerde ise birimlerin merkezi ölçüler etrafında belirgin bir toplanma göstermediği gözlenmektedir.

Basıklık Formülü:

$\alpha_4 = \mu_4 / \sigma^4$ ($\mu_4 = \Sigma(X_i - \bar{X})^4 / N$)

- $\alpha_4 = 3$ → Normal (mesokurtic) seri
- $\alpha_4 < 3$ → Basık (platykurtic) seri
- $\alpha_4 > 3$ → Sivri (leptokurtic) seri

Basıklık = $\alpha_4 - 3$

Negatif değerler basık, pozitif değerler de serilerin sivri olduğunu göstermektedir. Normal serilerde ise bu değer doğal olarak sıfırdır.

Serilerin basıklıklarının 3 ile değerlendirilmesinin nedeni istatistikte büyük önemi olan "Normal Dağılımın" basıklığının 3 olduğunun saptanmış olmasıdır.

ÖRNEK: Fiyat Serisi Basıklığı

$\mu_4 = 1,9444 / 5 = 0,389$

$\alpha_4 = 0,389 / 0,193 = 2,016$

Basıklık = $2,016 - 3 = -0,984$

→ Basık (platykurtic) seri ($\alpha_4 < 3$)

ÖRNEK: Eğitim Serisi Basıklığı

$\mu_4 = 202 / 50 = 4,04$

$\alpha_4 = 4,04 / 1,94 = 2,08$

Basıklık = $2,08 - 3 = -0,92 < 0$

→ Basık seri. Momentlere dayanan ölçülere göre işçilerin eğitim serisi simetrik kabul edilebilecek basık bir seridir.

ÖRNEK: Ücret Serisi Basıklığı

$\mu_4 = 53792 / 50 = 1075,84$

$\alpha_4 = 1075,84 / 452,83 = 2,38 < 3$

Basıklık = $2,38 - 3 = -0,62 < 0$

→ İşçilerin ücret serisi çok hafif sağa çarpık ve diğerlerine oranla basıklık açısından normal seriye daha yaklaşmış bir seridir.

3. ORANLAR

Bilindiği gibi birimlerin herhangi bir nitel veya nicel özelliğinin şıklarına göre dağılımının birim toplamı içindeki ağırlıklarını yüzde olarak gösteren rakamlara "Oran (Proportion)" adı verilmektedir.

Anakütlede: P = A / N Örnekte: p = a / n

Diğer şıkka sahip olma oranı:

> **Anakütlede: (1−P) = Q = (N−A) / N Örnekte: (1−p) = q = (n−a) / n**

0 ve 1 arasında çeşitli değerler alan oranlar yorum yapılırken yüzde olarak (100 ile çarpılarak) ifade edilmektedir. Özelliklerin tüm şıkları için hesaplandığında doğal olarak oran toplamları 1 veya 100 olmaktadır.

4. İKİ ANAKÜTLE ARASINDAKİ FARKIN TESTLERİ (BAĞIMSIZ ÖRNEKLER)

Birçok araştırmada iki anakütle ortalamaları arasındaki farkların test edilmesi gerekmektedir. Örneğin iki satış bölgesindeki potansiyel müşterilerin aylık ortalama gelirleri arasında fark olup olmadığı, aynı sınıfın iki şubesinde belirli bir dersten alınan not ortalamaları arasında fark olup olmadığı incelenmek istendiğinde bu tip hipotez testlerinin uygulanması gerekmektedir.

Ortalamaları $\bar{X}_1$ ve $\bar{X}_2$ standart sapmaları σ_1 ve σ_2 olan N_1 ve N_2 büyüklüğündeki iki anakütlenin birincisinden n_1, ikincisinden n_2 büyüklüğünde tesadüfi bağımsız örnekler çekildiğinde bu örneklerin ortalamaları arasındaki farkların beklenen değeri anakütle ortalamaları arasındaki farka eşittir: $E(\bar{x}_1 - \bar{x}_2) = \bar{X}_1 - \bar{X}_2$

4.1 Standart Hata

Anakütle standart sapmaları σ_1 ve σ_2 biliniyorsa:

$$\sigma(\bar{x}_1 - \bar{x}_2) = \sqrt{(\sigma_1^2/n_1 + \sigma_2^2/n_2)}$$

4.2 Aşamalar

1. Hipotezlerin yazılması:

- Çift taraflı: $H_0: \bar{X}_1 = \bar{X}_2$ / $H_1: \bar{X}_1 \neq \bar{X}_2$
- Sol kuyruk: $H_0: \bar{X}_1 \geq \bar{X}_2$ / $H_1: \bar{X}_1 < \bar{X}_2$
- Sağ kuyruk: $H_0: \bar{X}_1 \leq \bar{X}_2$ / $H_1: \bar{X}_1 > \bar{X}_2$

2. Anlamlılık düzeyinin saptanması (α)

3. Test İstatistiği:

$$Z = (\bar{x}_1 - \bar{x}_2) - (\bar{X}_1 - \bar{X}_2) / \sigma(\bar{x}_1 - \bar{x}_2) \text{ (σ bilindiğinde)}$$

H_0 altında $\bar{X}_1 - \bar{X}_2 = 0$ kabul edildiğinden → $Z = (\bar{x}_1 - \bar{x}_2) / \sigma(\bar{x}_1 - \bar{x}_2)$

4. Karar Aşaması:

- Çift taraflı: $|Z| > |Z(\alpha/2)| \rightarrow H_0$ red ; $|Z| \leq |Z(\alpha/2)| \rightarrow H_0$ kabul
- Sol kuyruk: $|Z| > |Z\alpha| \rightarrow H_0$ red ; $Z \geq Z\alpha \rightarrow H_0$ kabul
- Sağ kuyruk: $Z > Z\alpha \rightarrow H_0$ red ; $Z \leq Z\alpha \rightarrow H_0$ kabul

ÖRNEK: Lastik Dayanıklılığı Testi

Bir ülkede ortalama dayanması 65.000km olan standart sapması 4.800km olan iki marka otomobil lastiği üretilmektedir. Dayanma dağılımlarının normal olduğu bilindiğine göre %1 anlamlılık düzeyinde her iki markanın dayanıklılığının eşit olup olmadığını araştırmak üzere her iki markadan tesadüfi olarak 25'er lastik seçilmiş ve ortalama dayanmanın 64.190km ve 65.450km olduğu saptanmıştır.

1) $H_0: \bar{X}_1 = \bar{X}_2$ (Dayanıklılık eşit) / $H_1: \bar{X}_1 \neq \bar{X}_2$ (Dayanıklılık farklı) → Çift taraflı

2) $\alpha = \%1$

3) $\sigma(\bar{x}_1 - \bar{x}_2) = \sqrt{(4800^2/25 + 4800^2/25)} = \sqrt{(921600 + 921600)} = \sqrt{1843200} = 1357{,}645$

$Z = (65450 - 64190) / 1357{,}645 = 1260 / 1357{,}645 = 0{,}928$

4) $Z(0{,}01/2) = Z(0{,}005) = 2{,}58$

2,58 > 0,928 → H_0 kabul. Aradaki fark anlamsız, iki markanın dayanıklılığı eşittir.

5. İKİ ANAKÜTLE ARASINDAKİ FARKIN TESTLERİ (BAĞIMLI ÖRNEKLER)

Aynı özellikleri taşıyan gruplara farklı uygulamaların (A ve B) yapılması sonucu ortalamalar arasındaki farkın anlamlı olup olmadığının araştırmasında kullanılan testlerdir. Aynı yaş ve eğitim düzeyindeki öğrencilere farklı iki yöntemle bir konunun anlatılması, aynı statüdeki işçilere farklı yöntemle işletme içi eğitim uygulanması, aynı yaş ve sağlık yapısında olan kişilere aynı hastalık için kullanılan farklı iki ilacın etkisi arasında fark olup olmadığının araştırılmasında bağımsız örneklerden farklı bir yol izlenmektedir.

Tesadüfi olarak seçilen birimlerin yarısına bir (A) diğer yarısına farklı bir uygulama (B) yapılmakta veya birimlerin tümüne sırayla farklı iki uygulama yapılarak elde edilen değerler arasında farklar incelenmektedir. Bu farklar ilk durumda benzer yapıdaki birimler eşleştirilerek alınmaktadır.

5.1 Formüller

$D_i = X(A_i) - X(B_i)$ (eşleştirilmiş farklar)

$\bar{D} = \Sigma D_i / n$ (farkların ortalaması)

$S_D = \sqrt{[(\Sigma D_i^2 - n\bar{D}^2) / (n-1)]}$ (farkların standart sapması)

Z veya $t = \bar{D} / (S_D / \sqrt{n})$

$n \geq 30$ ise Z, $n < 30$ ve her iki anakütle normal dağılıyorsa t standart değişkeni kullanılır.

ÖRNEK 1: Bağımlı Küçük Örnek, Alt Kuyruk Testi

İstatistik dersinde başarıyı artırmak için geliştirilen bir eğitim yönteminin etkili olup olmadığını araştırmak üzere aynı sınıftan tesadüfi olarak seçilen 20 öğrencinin yarısına eski yöntemle yarısına yeni yöntemle bir istatistik teknik anlatılmıştır. %5 anlamlılık düzeyinde yeni yöntemin etkisi:

Eski (A)	Yeni (B)	D_i	D_i^2
30	35	−5	25
30	30	0	0
20	25	−5	25
40	38	2	4
43	40	3	9
58	60	−2	4
60	63	−3	9
62	58	4	16
70	72	−2	4
80	85	−5	25
Σ		−13	121

1) H_0: $\bar{X}_A \geq \bar{X}_B$ (Yeni eğitim yöntemi etkisiz) / H_1: $\bar{X}_A < \bar{X}_B$ (Yeni eğitim yöntemi etkili)

A: eski yöntemle, B: yeni yöntemle eğitilen öğrencileri temsil etmektedir.

2) α = %5

3) $\bar{D} = -13 / 10 = -1,3$

$S_D = \sqrt{[(121 - 10\times(1,3)^2) / (10-1)]} = \sqrt{[(121 - 16,9) / 9]} = \sqrt{(104,1/9)} = 3,4$

$t = (-1,3) / (3,4 / \sqrt{10}) = -1,3 / 1,0752 = -1,21$

4) $t(0,05; 9) = 1,833$ → $n < 30$ olduğu için t testi

−1,833 < −1,21 → |t_tablo| > |t_hesap| → H₀ kabul, yeni yöntem etkisizdir.

ÖRNEK 2: Bağımlı Büyük Örnek, Sağ Kuyruk Testi

Saatte üretilen parça sayısının artması için önerilen müzik yayınının gerçekten etkili olup olmadığını %1 anlamlılık düzeyinde test etmek üzere tesadüfi olarak seçilen 80 işçinin yarısına müzikle (A) diğer yarısına ise müziksiz üretim (B) yaptırılmıştır. $\bar{D} = 55$, $\Sigma D_i^2 = 280100$

1) H_0: $\bar{X}_A \leq \bar{X}_B$ (Müzik etkisiz) / H_1: $\bar{X}_A > \bar{X}_B$ (Müzik etkili) → Sağ kuyruk

2) α = %1

3) $S_D = \sqrt{[(280100 - 40 \times 55^2) / 39]} = \sqrt{[(280100 - 121000) / 39]} = \sqrt{(159100/39)} = 63,87$

$Z = 55 / (63,87 / \sqrt{40}) = 55 / 10,1 = 5,45$

4) Z(0,01) = 2,33 → 5,45 > 2,33 → H₀ red. Müzik saatte üretilen ortalama parça sayısı üzerinde etkilidir.

ÖRNEK 3: Bağımlı Büyük Örnek, Çift Taraf Testi

İlk kalp krizini geçirme yaşının erkek ve kadınlarda aynı olup olmadığını %5 anlamlılık düzeyinde araştırmak için aynı yaş, hayat tarzı ve sağlık durumu olan 50 kadın (A) ve 50 erkek (B) tesadüfi olarak seçilmiştir. $\bar{D} = 8$, $S_D = 24$

1) H_0: $\bar{X}_A = \bar{X}_B$ / H_1: $\bar{X}_A \neq \bar{X}_B$ → Çift taraflı

2) α = %5

3) $Z = 8 / (24/\sqrt{50}) = 8 / 3,394 = 2,357$

4) Z(0,05/2) = 1,96 → 2,357 > 1,96 → H₀ red. İlk kalp krizi geçirme yaşı kadın ve erkeklerde farklıdır.

6. TEK YÖNLÜ VARYANS ANALİZİ (ANOVA)

İkiden fazla anakütle ortalaması arasındaki farkın anlamlı olup olmadığının araştırılmasında kullanılan bir tekniktir. İki anakütle arasındaki farkın testlerinde de kullanılabilmekte ve t veya Z testleriyle aynı sonucu vermektedir.

Ancak varyans analizinin uygulanabilmesi için örneklerin seçildiği anakütlelerin normal dağılması ve varyansların eşit olması (eşit varyanslılık şartı — homoscedasticity) gerekmektedir. F testlerin geçerliliği özellikle varyans eşitliği şartına bağlıdır. Bu durumdan sapmalar olduğunda (farklı varyanslılık) F testlerinin sonuçlarına güvenilmez. Normallikten önemsiz sayılabilecek sapmalar ise testin etkinliğini bozmaz.

6.1 Hipotezler

H_0: $\bar{X}_1 = \bar{X}_2 = \bar{X}_3 = \ldots = \bar{X}c$ (c sayıdaki anakütlelerin ortalamaları birbirine eşittir)

H_1: c sayıdaki anakütle ortalamasından en az biri diğerlerinden farklıdır.

6.2 F İstatistiği

$F = \sigma^2_b / \sigma^2_w$ = Açıklanan Varyans / Açıklanamayan Varyans = Sütunlararası / Sütunlar İçi

Her anakütleden seçilen birim sayısı eşit olduğunda (r):

$$\sigma^2_b = r \times \Sigma(\bar{x}_j - \bar{x})^2 / (c-1)$$

$$\sigma^2_w = \Sigma\Sigma(x_{ij} - \bar{x}_j)^2 / c(r-1)$$

Eşit olmadığında payda c(r−1) yerine n − c geçmektedir.

6.3 Notasyonlar

r: satır sayısı (row) veya her anakütleden seçilen birim sayısı

c: sütun sayısı (column) veya anakütle sayısı

$\bar{x}_j$: sütun ortalaması, her anakütleden seçilen örneğin ortalaması

$\bar{x}$: genel (büyük) ortalama = $\Sigma x_{ij} / n$

x_{ij}: gözlenen birimlerin (n veya rc adet) değerleri

6.4 Serbestlik Dereceleri ve Karar

f_1 (1. serbestlik derecesi) = c − 1

f_2 (2. serbestlik derecesi) = n − c

Toplam = n − 1

$F(\alpha; f_1, f_2) < F_hesap \rightarrow H_0$ red, en az bir ortalamanın diğerlerinden farklı olduğu anlaşılır

$F(\alpha; f_1, f_2) \geq F_hesap \rightarrow H_0$ kabul, anakütle ortalamaları arasında fark yoktur

6.5 ANOVA Tablosu

Değişkenlik Kaynağı	Kareler Toplamı	Serbestlik Derecesi	Kareler Ort. (Varyans)	Test İst. F
Açıklanan (Sütunlar arası)	$\Sigma r(\bar{x}_j - \bar{x})^2$	c − 1	σ^2_b	σ^2_b / σ^2_w
Açıklanamayan (Sütunlar içi)	$\Sigma\Sigma(x_{ij} - \bar{x}_j)^2$	c(r−1) veya n−c	σ^2_w	
Toplam	$\Sigma\Sigma(x_{ij} - \bar{x})^2$	n − 1	σ^2	

6.6 Yorum

Varyans analizinde H_0 kabul edildiğinde, anakütle ortalamaları arasında hiç bir fark olmadığı, bir fark varsa bile bu farkın tesadüflerden kaynaklandığı ve anakütlelerde böyle bir fark olmadığı anlaşılmaktadır. Diğer bir ifadeyle anakütleler incelenen özellik (faktör) açısından birbirinden farklı değildir. Sanki hepsi tek bir anakütle özelliği göstermektedir.

H_0 reddedilmişse anakütle ortalamaları arasında fark var veya en az biri diğerlerinden farklıdır kararı alınmış demektir. Diğer bir ifadeyle farklı anakütleler söz konusudur.

ÖRNEK: Üç Fabrika Emek Prodüktivitesi

Bir işletmede üretim üç fabrikada yapılmaktadır. Bu fabrikalarda işçilerin saatte ürettikleri parça sayısı olarak hesaplanan emek prodüktivitesinin aynı olup olmadığını araştırmak üzere her üç fabrikadan tesadüfi olarak beşer işçi seçilmiş ve saatte ürettikleri ortalama parça sayısı belirlenmiştir. %1 anlamlılık düzeyine göre:

İşçiler	I. Fabrika	II. Fabrika	III. Fabrika
1	15	15	19
2	10	10	12
3	9	12	16
4	5	11	16
5	16	12	17
Σx_{ij}	55	60	80
$\bar{x}_j$	11	12	16

Genel ortalama: $\bar{x} = (55+60+80) / 15 = 195 / 15 = 13$

(veya gözlenen işçi sayısı aynı olduğu için r=5: $\bar{x} = (11+12+16) / 3 = 13$)

Açıklanan Varyans (σ^2_b):

$\sigma^2_b = r \times \Sigma(\bar{x}_j - \bar{x})^2 / f_1 = 5 \times [(11-13)^2 + (12-13)^2 + (16-13)^2] / (3-1)$

$= 5 \times [4 + 1 + 9] / 2 = 5 \times 14 / 2 = 70 / 2 = 35$

Açıklanamayan Varyans (σ^2_w):

Fab.I: $(15-11)^2+(10-11)^2+(9-11)^2+(5-11)^2+(16-11)^2 = 16+1+4+36+25 = 82$

Fab.II: $(15-12)^2+(10-12)^2+(12-12)^2+(11-12)^2+(12-12)^2 = 9+4+0+1+0 = 14$

Fab.III: $(19-16)^2+(12-16)^2+(16-16)^2+(16-16)^2+(17-16)^2 = 9+16+0+0+1 = 26$

$\sigma^2_w = (82+14+26) / 3(5-1) = 122 / 12 = 10,17$

$F = 35 / 10,17 = 3,44$

Kaynak	KT	SD	Varyans	F
Açıklanan	70	$3-1=2$	$\sigma^2_b=35$	3,44
Açıklanamayan	122	$3(5-1)=12$	$\sigma^2_w=10,17$	
Toplam	192	$15-1=14$	$\sigma^2=13,71$	

$F(0,01; 2, 12) = 6,93 > 3,44 \rightarrow H_0$ kabul.

→ %1 anlamlılık düzeyinde fabrikalar arasında emek prodüktivitesi farklılığı söz konusu değildir.

7. REGRESYON VE KORELASYON ANALİZİ

Regresyon ve korelasyon analizi, nedensellik ilişkisini ortaya koyan, uzun yıllardır kullanılan istatistiksel bir yöntemdir.

Regresyon analizi, bağımlı değişkenin sayısal bir değerden oluşması ve bu değerin tahmin edilmesinde kullanılmaktadır. Regresyon analizi, herhangi bir değişkenin, bir veya birden fazla değişkenle arasındaki ilişkiyi matematik bir fonksiyon ile ifade ederek tahmin yapmaya imkân tanır.

Korelasyon analizi ile değişkenler arasındaki ilişki ve ilişkinin gücü ölçülmekte iken regresyon analizinde ise elde edilen regresyon denklemi aracılığıyla ileriye dönük tahminler yapılmaktadır.

7.1 Korelasyon Analizi

Korelasyon iki ya da daha fazla değişken arasındaki doğrusal ilişkiyi gösterir. Korelasyon, bağımlı değişken ile bağımsız değişken arasındaki doğrusal ilişkinin gücünü derece olarak gösteren ve yüzde olarak ifade edilen bir değerdir. Bu değer, −1 ile +1 arasında olacaktır.

Değişkenler arasında, belirli bir korelasyon olmasına rağmen ilişki her zaman için doğrusal olmak zorunda değildir. Değişkenler arasında, doğrusal ya da doğrusal olmayan ilişki olabileceği gibi herhangi bir ilişki olmayabilir de.

Doğrusal İlişki:

Doğrusal ilişki, pozitif yönlü ya da negatif yönlü olabilir. Değişkenler arasındaki ilişki pozitif yönlü ise bir değişkenin aldığı değer artarken diğeri de artacaktır. Bu durumda korelasyon katsayısı, "+" değer alacaktır. Değişkenler arasındaki ilişki negatif yönlü ise bir değişkenin aldığı değer artarken, diğeri azalacaktır. Bu durumda korelasyon katsayısı, "−" değer alacaktır.

İlişki Olmaması:

Değişkenler arasında bazı durumlarda ilişki olmayabilir. Bu durum, bağımsız değişkenin farklı değerlerine karşılık tek bağımlı değişken değerinin olması ya da bağımlı değişkenin farklı değerler almasına rağmen tek bağımsız değişken değerinin olmasından kaynaklanır.

Doğrusal Olmayan İlişki:

Değişkenler arasında doğrusal bir ilişkinin bulunmaması, aralarında korelasyon olmadığı anlamına gelmez.

Pearson Korelasyon Katsayısının Yorumu:

- r = −1 → Tam negatif doğrusal ilişki
- r = +1 → Tam pozitif doğrusal ilişki
- r = 0 → İki değişken arasında doğrusal ilişki yok

r değeri	İlişki Düzeyi
0,00	İlişki yok
0,01 − 0,29	Düşük düzeyde ilişki
0,30 − 0,70	Orta düzeyde ilişki
0,71 − 0,99	Yüksek düzeyde ilişki
1,00	Mükemmel ilişki

Açıklanan Varyans (Determinasyon Katsayısı r^2):

Değişkenlerden birindeki değişimin ne kadarının diğer değişken tarafından açıklandığının yüzde olarak ifade edilebilmesini sağlar. Değişkenlerin birbirlerinde açıkladıkları varyans miktarı

korelasyon katsayısının karesine eşittir ve buna determinasyon katsayısı denir.

Örneğin Türkçe başarısı ile okuma hızı arasındaki korelasyon r=0,80 olsun. Buna göre determinasyon katsayısı r^2=0,64'dür. Öğrencilerin okuma hızındaki toplam değişkenliğin %64'ü Türkçe dersindeki başarılarından kaynaklanmaktadır. Geriye kalan %36'lık varyansın da başka değişkenlerden kaynaklandığı söylenebilir.

7.2 Korelasyon Hesaplama

$r = \sqrt{(1 - HKT / BKT)}$ veya $r = \sqrt{(1 - \Sigma(y-y')^2 / \Sigma(y-\bar{y})^2)}$

BKT = AKT + HKT → $\Sigma(y-\bar{y})^2 = \Sigma(y'-\bar{y})^2 + \Sigma(y-y')^2$

7.3 Basit Doğrusal Regresyon

Basit doğrusal regresyon analizi, tek bağımlı değişken(y) ve tek bağımsız değişkenin(x) olması durumunda, bağımsız değişkenin alacağı yeni değer için bağımlı değişkenin tahmin edilmesinde kullanılabilecek bir analizdir.

Regresyon denklemi: $y = b_0 + b_1x + \varepsilon$

• Y: bağımlı değişken • X: bağımsız değişken • b_0: sabit (y kesim noktası) • b_1: eğim (regresyon katsayısı) • ε: hata

b_1 işareti iki değişken arasındaki ilişkinin yönünü göstermektedir. Bir başka ifade ile bağımsız değişken x'de bir birimlik değişmenin bağımlı değişken y'de ne kadarlık bir değişme yarattığını gösteren regresyon katsayısıdır. x'in sıfır olması durumunda b_0 değeri, regresyon doğrusunun dikey eksen y'yi kestiği noktayı göstermektedir.

7.4 En Küçük Kareler Yöntemi — Normal Denklemler

Türev alınarak, normal denklemlerin elde edilmesine en küçük kareler yöntemi denir:

$\Sigma y = n \cdot b_0 + b_1 \cdot \Sigma x$

$\Sigma xy = b_0 \cdot \Sigma x + b_1 \cdot \Sigma x^2$

7.5 Regresyon Varsayımları

- Bağımlı değişken tesadüfi değişkendir, normal dağılır.
- Hatalar tesadüfidir, normal dağılır.
- Hatalar birbirinden bağımsızdır (otokorelasyon yoktur).
- Her bağımsız değişkenin değerlerine ait olan bağımlı değişken değerlerinin alt kümelerinin varyansları birbirine eşittir (Homoskedastisite).
- Bağımsız değişkenler arasında basit doğrusal ilişki olmamalıdır (Çoklu doğrusal bağlantı).
- Bağımlı değişken mutlaka sürekli olmalıdır.

ÖRNEK 1: Matematik-İstatistik Notu

İstatistik dersinde başarının matematik dersinden başarıya bağımlı olup olmadığını araştırmak üzere 8 öğrenci seçilmiştir.

y (İstatistik)	x (Matematik)	x·y	x²	y'(tahmin)	(y−ȳ)²	(y−y')²
10	20	200	400	12,5	1600	6,25
20	30	600	900	21,875	900	3,52
30	50	1500	2500	40,625	400	112,9
50	60	3000	3600	50	0	0
60	70	4200	4900	59,375	100	0,4
70	100	7000	10000	87,5	400	306,25
80	70	5600	4900	59,375	900	425,4
80	80	6400	6400	68,75	900	126,6
Σ=400	Σ=480	Σ=28500	Σ=33600	Σy'=400	BKT=5200	HKT=981,25

n=8, Σy=400, Σx=480, Σxy=28500, Σx²=33600

A) Normal denklemler:

$400 = 8b_0 + 480b_1$ ....(1)

$28500 = 480b_0 + 33600b_1$ ....(2)

(2)'yi −60'a böl: $-475 = -8b_0 - 560b_1$ → (1) ile topla:

$-75 = -80b_1 \rightarrow b_1 = 0{,}9375$

$400 = 8b_0 + 480\times0{,}9375 \rightarrow 400 = 8b_0 + 450 \rightarrow b_0 = -50/8 = -6{,}25$

→ Regresyon denklemi: y = −6,25 + 0,9375x

B) x = 90 için tahmin:

$y = -6{,}25 + 0{,}9375 \times 90 = -6{,}25 + 84{,}375 = 78{,}125$

→ Matematikten 90 alan bir kişinin tahminen istatistik dersinden 78,125 alması beklenir.

C) Korelasyon katsayısı:

$\bar{y} = 400/8 = 50$

$BKT = \Sigma(y-\bar{y})^2 = 5200$ | $HKT = \Sigma(y-y')^2 = 981{,}25$

$r = \sqrt{(1 - 981{,}25/5200)} = \sqrt{(1-0{,}1887)} = \sqrt{0{,}8113} = 0{,}9007$

→ Matematik dersinden alınan not ile İstatistik dersinden alınan not arasında %90,07 korelasyon vardır. (Yüksek düzeyde pozitif ilişki)

ÖRNEK 2: Kişi Sayısı — Su Tüketimi

Bir ailede yaşayan kişi sayısı (x) ile aylık su tüketimi (y, m³):

y (Su m³)	x (Kişi)	x·y	x²	y'(tahmin)	BKT	HKT
20	4	80	16	18	4	4
20	4	80	16	18	4	4
14	2	28	4	13,14	16	0,73
12	2	24	4	13,14	36	1,31
14	3	42	9	15,57	16	2,47
12	2	24	4	13,14	36	1,31
22	5	110	25	20,43	16	2,47
22	6	132	36	22,86	16	0,73
24	7	168	49	25,29	36	1,65
20	5	100	25	20,43	4	0,18
Σ=180	Σ=40	Σ=788	Σ=188	Σy'=180	BKT=184	HKT=18,86

n=10, Σy=180, Σx=40, Σxy=788, Σx²=188

Normal denklemler: $180 = 10b_0 + 40b_1$ | $788 = 40b_0 + 188b_1$

(1)'i -4 ile çarp ve topla: $68 = 28b_1 \rightarrow b_1 = 2{,}4286$

$180 = 10b_0 + 40 \times 2{,}4286 \rightarrow 10b_0 = 82{,}856 \rightarrow b_0 = 8{,}2856$

→ Regresyon denklemi: $y = 8{,}2856 + 2{,}4286x$

B) 8 kişi: $y = 8{,}2856 + 2{,}4286 \times 8 = 27{,}71\ m^3$

→ 8 kişilik bir ailenin tahminen 27,71 m^3 su tüketmesi beklenir.

C) $\bar{y} = 180/10 = 18$

BKT = 184 | HKT = 18,86

$r = \sqrt{(1 - 18{,}86/184)} = \sqrt{0{,}8975} = 0{,}9474$

→ Ailede yaşayan kişi sayısı ile su tüketimi arasında %94,74 korelasyon vardır. (Yüksek düzeyde pozitif ilişki)

7.6 Korelasyon vs Regresyon Karşılaştırması

Karşılaştırma	Korelasyon	Regresyon
Anlam	İki değişken arasındaki ilişkiyi belirleyen istatistiksel bir ölçüdür.	Bağımsız bir değişkenin, bağımlı değişkenle sayısal olarak nasıl ilişkili olduğunu açıklar.
Kullanım	İki değişken arasındaki doğrusal ilişkiyi göstermek	En iyi satıra sığdırmak ve bir değişkeni başka bir değişken temelinde tahmin etmek
Bağımlı ve Bağımsız Değişken	Hangisinin bağımlı hangisinin bağımsız değişken olduğu fark etmez.	İki değişken de farklıdır. Doğru belirlenmesi önemlidir.
Gösterge	Korelasyon katsayısı, iki değişkenin birlikte hareket etme derecesini gösterir.	Yordayıcı değişkendeki (x) bir birim değişikliğinin yordanan değişken (y) üzerindeki etkisini gösterir.
Amaç	Değişkenler arasındaki ilişkiyi ifade eden sayısal bir değer bulmak.	Sabit değişkenli değerleri baz alarak rasgele değişkenin değerlerini tahmin etme.

7.7 Regresyon Analizinin 4 Temel Amacı

• Bağımlı ve bağımsız değişken arasındaki ilişkiyi regresyon ile açıklamak

• Regresyon modelinin bilinmeyen parametreleri tahmin edildiğinde, bağımsız değişken/lerin bilinen değeri için bağımlı değişkenin değerini tahmin etmek

• Bağımsız değişken/lerin bağımlı değişkende gözlenen değişmelerin ne kadarını açıkladıklarını determinasyon katsayısı ile belirlemek

• Bağımsız değişken ya da değişkenlerin bağımlı değişkeni manidar bir şekilde kestirip kestirmediklerini; birden fazla bağımsız değişken var ise bunların bağımlı değişken üzerindeki göreli önemliliklerini saptamak