YBS 301 Veri Madenciliği – Sınav Çalışma Notu

İçindekiler

- Kapsam ve sınav uyarıları
- **Hafta 1**
  - Neden VM, algoritma, tarihçe, disiplinler
  - DIKW piramidi
  - VM kavramı, veri ambarı, OLAP
  - KDD süreci
  - Veri ön işleme
  - Veri madenciliği modelleri
  - İstatistik vs VM, uygulama alanları
  - Yanlılıklar ve safsatalar
  - EDA: 7 veri seti ve 12 soru
- **Hafta 2**
  - Veri hazırlama ve temel kavramlar
  - Değişken tipleri
  - İstasyon 1: Temizleme
  - İstasyon 2: Birleştirme
  - İstasyon 3: İndirgeme
  - İstasyon 4: Dönüştürme ve normalleştirme
- Python kütüphaneleri
- Pestil & Köme lab
- Soru-cevap
- Son tekrar listesi

Kapsam ve sınav uyarıları

Bu not yalnızca YBS-DataMining reposundaki iki haftayı kapsar: 1. Hafta (Temel Kavramlar + EDA) ve 2. Hafta (Verinin Hazırlanması). 3–14. haftalar repoda henüz boş.

Kaynak	İçerik
hafta1/README.md	7 veri seti, yükleme kodları, 12 soruluk EDA listesi
hafta1/YBS301_..._Hafta1.md	Temel kavramlar, KDD, ön işleme, modeller, safsatalar
hafta2/README.md	Pestil & Köme vaka özeti, lab görev başlıkları
hafta2/YBS301_..._Hafta2.md	Değişken tipleri, 4 istasyon, normalleştirme, Python/R kodları
hafta2/gumushane_pestil_kome_veriseti/readme.md	Lab görevlerinin ayrıntısı
pratik/readme.md	NumPy ve Pandas notebook hedefleri

Okunamayanlar: ders1.pptx, 2.pptx ve .ipynb notebook'ları doğrudan okunmadı. Çalışma notları "kitap + sunum birleştirilerek" hazırlandığı için slayt içeriği büyük ölçüde kapsanıyor; yine de slaytlara bir göz at.

Hocanın kendi düzelttiği iki kitap hatası (sınavda tuzak olabilir):

- Z-skor sonucu 0 ile 1 arasında **değildir**. Ortalama 0, standart sapma 1 olur; değerler çoğunlukla −3 ile +3 arasına düşer, negatif ve 1'den büyük değerler çıkar.
- Kitaptaki örnekte 379'un z-skoru 0,770 yazıyor; doğrusu **0,767**.

1. Hafta: Neden veri madenciliği, algoritma, tarihçe, disiplinler

Veri madenciliği (VM), toplanması kolay ama anlamlandırılması zor büyük veriden karar destek bilgisi çıkarmak için doğdu. Çözümün kendisi değil, doğru karara destek olan bir **araçtır**.

Neden ortaya çıktı?

- Bilişim teknolojileri ekonomik koşulları, müşteri beklentilerini ve rakip stratejilerini hızla değiştiriyor.
- Yöneticiler **zamanında elde edilmiş doğru bilgiyle** karar vermek zorunda.
- Veri toplamak ve saklamak kolay; ondan anlamlı bilgi çıkarmak zor.
- Geleneksel analiz yöntemleri veri hacmindeki artış karşısında yetersiz kaldı.

Algoritma kavramı

Kelime, Harezmli matematikçi **Harezmi (Al-Khwarizmi)** adından gelir. Algoritma, bir problemi çözmek için çözüm yolunun **adım adım** tasarlanmasıdır.

Problem türü	Tanım	Örnek
Algoritmik	Adımları net tanımlanabilir	Sıralama, en kısa yol
Algoritmik olmayan	Kesin adımlarla tarif edilemez	Yüz tanıma, kediyi ayırt etme, iyi hamleyi sezme

Makine öğrenimi ve VM, algoritmik olmayan problemlerde devreye girer.

Tarih	Olay	Neden önemli
11 Mayıs 1997	IBM Deep Blue, Kasparov'u yendi	Kaba kuvvet arama + uzman bilgisi
15 Mart 2016	Google AlphaGo, Lee Sedol'u 4-1 yendi	Go'da hamle sayısı çok fazla; sistem veriden öğrendi

Tarihsel gelişim

Dönem	Gelişme
1950'ler	İlk bilgisayarlar; 1957'de Frank Rosenblatt **perseptronu** geliştirdi (yapay nöronun ilk modeli)
1960'lar	Veritabanı kavramı; 1969'da Minsky ve Papert perseptronun basit mantıksal işlemlerde yetersizliğini gösterdi; hiyerarşik ve ağ veri modelleri
1970'ler	İlişkisel VTYS; kurala dayalı uzman sistemler
1980'ler	VTYS'ler yaygınlaştı; işletmeler müşteri, rakip, ürün verisini saklamaya başladı
1989	**KDD (IJCAI-89) çalışma grubu** toplantısı; KDD terimi doğdu
1991	Toplantının sonuç makalesi: temel tanım ve kavramlar
1992	VM için ilk yazılım
2000'ler	Tüm alanlara yayıldı; CRM ve ERP ile iş dünyasında yaygınlaştı

İlk zamanlarda "veri taraması", "veri yakalama" denirdi; "veri madenciliği" adı 1990'larda bilgisayar mühendislerince kullanılmaya başlandı.

Veri madenciliğine etki eden disiplinler

VM tek bir alan değil, birçok disiplinin kesişimidir.

Disiplin	Kısaca
İstatistik	Klasik veri analizi; bilgisayar gücüyle eskiden yapılamayanlar mümkün oldu
Makine öğrenimi	Bilgisayarın örneklerden çıkarım yaparak öğrenmesi; yapay zekânın temeli
Görselleştirme	Veriyi tablo/grafikle sunmak; boyut arttıkça yeni araçlar gerekti
Veritabanı sistemleri	VM'nin "olmazsa olmazı"
Örüntü tanıma	Tanımlı bir örüntünün (parmak izi, ses, yüz, el yazısı) benzerlerini bulmak

Mantığı: Makine öğrenimi, kediyi ilk kez gören bir çocuk gibidir. Her yeni kediyle "kedi" kavramı netleşir; çocuk ortak özelliklere bakarak sınıflandırmayı öğrenir. Makine de örneklerden ortak özellik çıkarıp yeni veriyi sınıflandırır.

#10yearchallenge şakası: 2009'da "istatistik" denen $y = \beta X + \varepsilon$, 2019'da "makine öğrenimi" diye anılıyor. Mesaj: yöntemlerin kökü istatistiktir.

DIKW piramidi: Veri → Enformasyon → Bilgi → Bilgelik

R. Ackoff'un (1989) DIKW piramidi, ham veriden karara giden yolu dört katmanda gösterir. Alt üç katman **geçmişi** anlamaya, en üst katman **geleceğe** yönelik karara hizmet eder.

Katman (alttan üste)	Cevapladığı soru	Tanım	Süreç
Veri	Hiçbir şey	Tek başına anlam taşımayan ham gözlem, sayı, sembol	Parçaları toplama
Malumat / Enformasyon	Ne?	Bağlam içinde ilişkilendirilmiş, düzenlenmiş veri	Parçaları bağlama
Bilgi	Nasıl? Neden?	Neden-sonuç ilişkisi kurulmuş, kavrayış sağlayan bilgi	Bütünün oluşması
Bilgelik	Neden yapmalı? En iyisi ne?	Birikmiş bilgiyi doğru karar için kullanmak	Bütünleri birleştirme

Örnek: Abraham Wald ve bombardıman uçakları (II. Dünya Savaşı)

Katman	Wald örneğindeki karşılığı
Veri	Dönen uçaklardaki delik sayıları ve konumları (kanatta 120, gövdede 95, motorda 3)
Enformasyon	Deliklerin kanat ve gövdede yoğunlaştığı, motor ve kokpitte neredeyse olmadığı harita
Bilgi	İsabetler rastgele dağılır; motor/kokpitten vurulanlar **geri dönemediği** için örneklemde yok. Boş görünen yerler ölümcül noktalardır
Bilgelik	Zırh sınırlı (ağırlık yavaşlatır) → zırhı **deliksiz görünen hayati bölgelere** ekle

Mantığı: Sadece "hayatta kalanlara" bakmak seni yanıltır. Bu örnek aynı zamanda **Hayatta Kalma Yanılgısı (Survivorship Bias)**'nın klasik örneğidir; sınavda iki konuyu birden sorabilirler.

Veri madenciliği kavramı, veri ambarı ve OLAP

VM ile elde edilen bilgi **daha önce bilinmeyen, tahmin bile edilemeyen** bilgidir; VM zaten bilinen bir sonucu doğrulamak için kullanılmaz.

Tanımlar (kitaptan)

- Büyük veri yığınlarında geleceği tahmin etmeye yardımcı **anlamlı ve yararlı ilişki ve kuralların** bilgisayar yazılımlarıyla aranmasıdır.
- Veriler arasındaki **örüntü (desen) ve ilişkileri** keşfedip doğru tahminler için kullanan bir **süreçtir**.
- İstatistiksel/matematiksel teknikler ve örüntü tanımayla yeni **korelasyon, örüntü ve eğilimlerin** keşfidir.

Madencilik benzetmesi: Altın, bor, kömür çıkarılıp işlenmedikçe değersizdir. Veritabanındaki veri de işlenmeyi bekleyen ham maddedir.

Diğer adları: bilgi çıkarımı, enformasyon keşfi, enformasyon hasadı, veri arkeolojisi, veri örüntü işleme.

Sık yapılan hata: VM ≠ KDD. VM, KDD sürecinin **yalnızca bir adımıdır**.

Veri ambarı ve ilgili kavramlar

İşlemsel (günlük kayıt tutan) veritabanları VM'de **doğrudan kullanılmaz**; önce hazırlanır.

1. İç ve dış veri kaynakları toplanır.
2. Veri çekilir, temizlenir, dönüştürülür.
3. Veri ambarına yüklenir (alt kümeleri: veri depoları / data mart).
4. Erişim, sorgulama ve analizle OLAP veya VM yapılır.

Kavram	Açıklama
İç veri kaynakları	İşletmenin kendi süreçleri (üretim, satın alma, pazarlama kayıtları)
Dış veri kaynakları	Sektör verileri, istatistik kurumu raporları, yasal düzenlemeler, döviz kurları
Veri ambarı (Data Warehouse)	İç + dış kaynakların birleştirildiği, **konu odaklı**, VM'ye hazır geniş veritabanı; **tüm işletmeyi** ilgilendirir
Üst veri (Metadata)	Ambardaki veriler hakkındaki tanımlamalar; ambarın "veri kataloğu"
Veri deposu (Data Mart)	Ambarın alt kümesi; **tek bir bölüm veya konuya** yönelik
OLAP	Çevrimiçi Analitik İşleme; ambardaki veri üzerinde **çok boyutlu** analiz ve sorgulama

Mantığı: Ambar = tüm şirketin deposu, data mart = bir bölümün rafı, metadata = depo kataloğu.

Sorgulama düzeyleri: SQL → OLAP → VM (kablo üreticisi örneği)

Düzey	Örnek soru	Araç
1. Basit sorgu	"Geçen ay toplam ne kadar halojensiz tesisat kablosu sattık?"	İşlemsel veritabanı / SQL
2. Çok boyutlu sorgu	"Ağustos'ta İç Anadolu'da ne kadar sattık; geçen ay, geçen yılın Ağustos'u ve tahminle karşılaştırması?"	OLAP (veri küpü: ürün × bölge × zaman × satış)
3. Gizli örüntü	Akla gelmemiş, tahmin edilemeyen ilişkiler	Veri madenciliği

İlk iki düzey **bilinen veya tahmin edilebilir** sonuçlar verir; VM **bilinmeyeni** arar.

KDD: Veritabanlarında Bilgi Keşfi süreci

KDD, veriden faydalı bilgi keşfetme sürecinin **tamamıdır**; terim 1989'daki çalışma toplantısında ortaya atıldı. Sürecin en çok zaman alan aşaması **veri ön işlemedir**.

Han ve Kamber gösterimi

1. Veritabanları / düz dosyalar
2. Veri temizleme ve bütünleştirme
3. Veri seçimi ve dönüştürme
4. Veri madenciliği
5. Örüntüler
6. Değerlendirme ve sunum
7. Bilgi

Beş aşama (kitap)

#	Aşama	Konum	Öz
1	Amacın tanımlanması	VM öncesi	Amaç probleme odaklı ve açık olmalı; başarı ölçütü, yanlış tahminin maliyeti, doğru tahminin kazancı tanımlanır
2	Veriler üzerinde ön işlemler	VM öncesi	Veriyi analize hazırlama; **en çok zaman alan aşama**
3	Modelin kurulması ve değerlendirilmesi	**VM'nin kendisi**	Birçok model denenir; en iyiye ulaşana kadar 2. ve 3. aşama tekrarlanır; geçerlilik sınanır
4	Modelin kullanılması ve yorumlanması	VM sonrası	Sonuç başlangıçtaki amaca ulaştı mı? Ulaşmadıysa süreç yenilenir
5	Modelin izlenmesi	VM sonrası	Koşullar değişir; model sürekli izlenir, gerekirse güncellenir

Mantığı: "Çöp girer, çöp çıkar" (Garbage in, garbage out). Ön işleme özensizse model aşamasından sürekli geri dönersin. KDD'yi bir mutfak gibi düşün: malzemeyi seçmek ve temizlemek (ön işleme) pişirmekten (model) uzun sürer.

Ezber kalıbı: Amaç → Ön işlem → Model → Yorum → İzleme. Sınavda "VM, KDD'nin hangi aşamasıdır?" sorusunun cevabı: **3. aşama, modelin kurulması ve değerlendirilmesi**.

Veri ön işleme (1. Hafta anlatımı)

Ön işleme üç işten oluşur: toplama/birleştirme, temizleme (kayıp veri + gürültü) ve yeniden yapılandırma (normalizasyon, azaltma, dönüştürme).

1. Verilerin toplanması ve birleştirilmesi
2. Verilerin temizlenmesi
    1. Kayıp veriler için işlem
    2. Gürültünün temizlenmesi
3. Verilerin yeniden yapılandırılması
    1. Normalizasyon
    2. Veri azaltma (indirgeme)
    3. Veri dönüştürme

Toplama ve birleştirme

Amaca uygun veri önce iç kaynaklarda, sonra kamu veritabanları veya veri satan kuruluşlar gibi dış kaynaklarda aranır. **Verinin hangi koşulda ve hangi yöntemle toplandığı önemlidir.**

Temizlemenin temel kavramları

Kavram	Tanım	Örnek
Kayıp veri	Kayıtta eksik değer	Doğum tarihi girilmemiş çalışan
Aykırı değer	Doğru olamayacak kadar uç değer	Doğum yılı 1974 yerine 1074
Gürültülü veri	Aykırı veya yanlış girilmiş değerlerin genel adı	—
Uyumsuzluk	Kaynaklar arası farklı birim, zaman, kodlama	Bir sistemde cinsiyet E/K, diğerinde 0/1

Kayıp verilerle başa çıkma

Yaklaşım	Ne zaman uygun	Dikkat
a. Kaydı silmek	Kayıp oranı çok küçükse	Oran yüksekse sonucu bozar
b. Elle doldurmak	Veri küçük, eksiğe ulaşılabilir, zaman var	Aksi hâlde zaman kaybı
c. Hepsine aynı sabit ("Y", "E", 9)	Hızlı çözüm	Algoritmayı yanıltabilir; kod başka anlamlı değerle çakışmamalı; bazen gizli örüntü de çıkarabilir
d. Ortalama ile doldurmak	Sayısal değişkenlerde	Genel ortalama yerine **sınıf ortalaması** daha uygun
e. Diğer değişkenlerle tahmin	Daha doğru doldurma için	Regresyon, zaman serisi, Bayes, karar ağacı, beklenti maksimizasyonu

Kira örneği: 6 numaralı, Alanönü mahallesinde oturan 9 yıllık çalışanın kirası eksik.

- Genel ortalama: (850 + 675 + 780 + 950 + 1250) / 5 = 4505 / 5 = **901**
- Sınıf ortalaması (yalnızca Alanönü'ndeki iki çalışan): **865**
- Hangisinin kullanılacağına karar verici karar verir.

Mantığı: Sınıf ortalaması daha isabetlidir, çünkü eksik kişiye benzeyen (aynı gruptaki) kişilerden tahmin yapar. Aynı mahalledeki kira, şehrin ortalamasından daha iyi tahmin verir.

Gürültüyü temizleme: bölmeleme (binning)

Örnek veri: 24, 18, 7, 27, 31, 24, 11, 37, 28

Adım 1 — Sırala: 7, 11, 18, 24, 24, 27, 28, 31, 37

Adım 2 — Üç eşit bölüme ayır ve düzelt:

Bölüm	Orijinal	Ortalama ile	Sınır değerleri ile
1	7, 11, 18	12, 12, 12	7, 7, 18
2	24, 24, 27	25, 25, 25	24, 24, 27
3	28, 31, 37	32, 32, 32	28, 28, 37

- **Ortalama/medyan ile:** Bölümdeki her değer bölüm ortalaması (veya medyanı) olur. Bölüm 1: (7 + 11 + 18) / 3 = 36 / 3 = 12.
- **Sınır değerleri ile:** Her değer, bölümün en küçük ya da en büyük değerinden hangisine yakınsa o olur. 11'in 7'ye uzaklığı 4, 18'e uzaklığı 7 → 7 olur. 31'in 28'e uzaklığı 3, 37'ye 6 → 28 olur.
- **Kitaptaki varyant:** (maks − min) / eleman sayısı bölüme atanır. Bölüm 1: (18 − 7) / 3 = 3,67.
- **Kümeleme:** Veri benzerliğe göre kümelenir; hiçbir kümeye girmeyen nokta aykırıdır ve en yakın kümenin ortalama/sınır değeriyle değiştirilir.
- **Regresyon:** Değişkenler arası ilişki bir fonksiyonla modellenir; biri diğerini tahmin eder (doğrusal / çoklu doğrusal).

Mantığı: Bölmeleme "komşularına bak" demektir. Uç bir değer, yakın komşularının ortalamasına çekilerek yumuşatılır. Sınav sorusu çözerken **önce sırala** adımını unutma; en sık yapılan hata budur.

Yeniden yapılandırma

Bazı algoritmalar yalnızca sayısal, bazıları kategorik, bazıları 0/1 verilerle çalışır; veri algoritmaya uygun hâle getirilir.

İşlem	Açıklama	Yöntem / Örnek
Normalizasyon	Değerleri 0–1 gibi ortak aralığa getirmek	Min-maks, sıfır-ortalama (z-skor), ondalıklı
Veri azaltma	Temel özelliği kaybetmeden veri miktarını azaltmak	Boyut azaltma, sıkıştırma, PCA, faktör analizi
Veri dönüştürme	Algoritmanın kullanabileceği biçime getirmek	1.500–5.000 TL maaşı "düşük/orta/yüksek" yapmak (kesikleştirme)

Veri madenciliği modelleri

Tüm modellerin ortak noktası **öğrenmedir**; modeller tahmin edici (denetimli, etiket var) ve tanımlayıcı (çoğunlukla denetimsiz, etiket yok) olarak ikiye ayrılır.

Ortak özellik: öğrenme döngüsü

1. Yazılım örnek veriyi inceler, kural çıkarır → **öğrenme**

2. Kuralları kalan veriye uygulayıp kendini sınar → **test**
3. Gerekirse kuralları yeniler → **doğrulama**
4. **Aşırı öğrenme (overfitting)** kontrol edilir: kurallar yalnızca eğitim verisinde işliyor, yeni veride çöküyorsa model **ezber** yapmıştır.

Mantığı: Overfitting, sınav sorularını ezberleyip soru biraz değişince çözemeyen öğrencidir.

Denetimli ve denetimsiz öğrenme

	Denetimli (Supervised)	**Denetimsiz (Unsupervised)**
Etiket / sınıf bilgisi	**Var** (her kaydın yanında "kadın/erkek" yazar)	**Yok**
Amaç	Yeni gözlemin etiketini tahmin etmek	Benzerliğe göre doğal grupları bulmak
Veri kullanımı	Eğitim kümesi + test kümesi	Tüm veri
Örnek	Sınıflandırma, regresyon	Kümeleme

Model sınıflandırması

Tahmin edici (Predictive): Regresyon, sınıflandırma, (zaman serisi analizi). Algoritmalar: karar ağaçları, yapay sinir ağları, genetik algoritmalar, k-en yakın komşu, Bayes sınıflandırması, destek vektör makineleri, hatayı geri yayma.

Tanımlayıcı (Descriptive): Kümeleme, birliktelik kuralları, sıra örüntü analizi, özetleme, (istisna/aykırı değer analizi, tanımlayıcı istatistik).

Tahmin edici modeller

Bilinenden yola çıkıp bilinmeyeni tahmin eder. Örnek: banka geçmiş kredi verisinden yeni müşterinin krediyi ödeyip ödemeyeceğini, hastane geçmiş vakalardan yeni hastanın teşhisini tahmin eder.

- **Regresyon:** Bağımlı ve bağımsız değişkenler arasındaki ilişkiyi en iyi tanımlayan fonksiyonu bulur; çıktı **sürekli** (sayı).
- **Sınıflandırma:** Veriyi önceden belirlenmiş sınıflara atar; çıktı **kategorik**; denetimlidir.

Algoritma	**Ana fikir**	**Artı / eksi**
Karar ağaçları	Kök düğümden başlar, her düğümde bir özellik test edilir, yapraklar sınıfı verir	En yaygın; anlaşılması ve kurulması kolay
Yapay sinir ağları	Biyolojik sinir sistemini taklit eder	Karmaşık, doğrusal olmayan ilişkileri modeller; **yorumlanması zor**
Genetik algoritmalar	Evrimi taklit eder: nüfus, kromozom, uygunluk fonksiyonu	Doğrudan VM modeli değil, **eniyileme** yöntemi
Zaman serisi analizi	Zamana bağlı verinin gelecek değerini tahmin eder	En yaygın alan borsa; denetimli
k-en yakın komşu (k-NN)	Yeni noktayı en yakın k komşusunun sınıfına atar (Öklid uzaklığı)	k çok büyük → farklı noktalar karışır; k çok küçük → benzerler ayrı sınıfa düşer, gürültüye duyarlılık artar
Bayes sınıflandırması	Bayes kuralıyla her sınıfa girme olasılığını hesaplar	Olasılık temelli, hızlı

Tanımlayıcı modeller

Verideki örüntü ve ilişkileri tanımlar; kayıtlar arasında bağlantı kurar.

Model	**Ne yapar**	**Örnek**
Kümeleme	Benzerliğe göre gruplar; hedef değişken yok (**denetimsiz**); kümelerin anlamını alan uzmanı yorumlar	Poliçesini yenilemeyen müşterilerin ortak özellikleri
Birliktelik kuralları	Birlikte görülen öğeleri bulur (pazar sepeti analizi)	"Bira alanların %80'i cips de alıyor" → raf düzeni, çapraz satış
Sıra örüntü analizi	Birliktelik + **zaman sırası**	"Çekiç alan müşteri ilk üç ayda %15 olasılıkla çivi alır"
Özetleme	Alt gruplara ayırıp ortalama, std gibi göstergeler üretir (karakterizasyon / genelleştirme)	Müşteri segment profili

Mantığı: Sınıflar **önceden biliniyorsa** sınıflandırma (denetimli); **bilinmiyorsa** kümeleme (denetimsiz). Birliktelik "ne ile ne birlikte", sıra örüntü "ne, neden sonra" sorusudur.

Diğer analiz yaklaşımları ve uygulama alanları

Geleneksel istatistik hipotezle başlar ve elle eşitlik kurar; VM hipotezsiz, otomatik keşif yapar ve gizli bilgiyi arar.

Geleneksel istatistik vs veri madenciliği

Geleneksel istatistik	Veri madenciliği
Bir **hipotez** kurarak başlar	Hipoteze ihtiyaç duymaz
İstatistikçi eşitlikleri **kendisi** geliştirir	Algoritmalar eşitlikleri **otomatik** geliştirir
Çoğunlukla **sayısal** veri	Sayısala ek olarak **metin, ses** vb.
Kirli veri analiz sırasında bulunup filtrelenir	**Temizlenmiş** veri üzerinde çalışır
Sonuçlar görece kolay yorumlanır	Yorumlamak zor, **uzman** gerekir

Kullanım amacına göre araç seçimi

Araç	Ne zaman
Veri sorgusu / SQL	Ne aradığını tam biliyorsan
OLAP	Çok boyutlu, basit ilişkileri incelemek istiyorsan
Veri madenciliği	Açıkça gözlenemeyen örüntü ve ilişkileri keşfetmek istiyorsan

Keşfedilen bilgi tipine göre

Bilgi tipi	Açıklama	Araç
Sığ bilgi	Veritabanından doğrudan sorgulanabilen	SQL
Çok boyutlu bilgi	Veri küpü üzerinden analiz edilebilen	OLAP
Gizli bilgi	Kolayca görülemeyen örüntü ve ilişkiler	Veri madenciliği
Derin bilgi	Bulunması için ipucu gereken, en zor erişilen	VM'nin araştırma sınırları

Mantığı: Sığ → çok boyutlu → gizli → derin sırası, "ne kadar kazman gerekiyor" sırasıdır.

Uygulama alanları

Büyük veri üretilen ve karar gereken her alan: pazarlama, finans (bankacılık, sigorta, borsa), perakende, sağlık, telekomünikasyon, endüstri, eğitim, tıp, biyoloji, genetik, kamu, istihbarat ve güvenlik.

Alan	Örnek uygulamalar
Pazarlama (en yoğun alan)	Müşteri segmentasyonu, pazar sepeti, kampanya hedefleme, müşteri kaybı (churn) tahmini
Finans	Kredi riski, kredi kartı dolandırıcılığı tespiti, borsa tahmini
Sağlık	Hastalık teşhisi ve risk tahmini, tedavi etkinliği, ilaç etkileri
Endüstri / mühendislik	Arıza tahmini, kalite kontrol, üretim optimizasyonu
Eğitim	Başarıyı etkileyen faktörler, okulu bırakma riski

Tarihî örnek — John Snow ve kolera (Londra, 1854): Snow kolera ölümlerini Soho haritasına işaretledi; vakalar **Broad Street'teki su pompası** çevresinde yoğunlaştı. Pompanın kolu çıkarıldı, salgın yavaşladı. Veri görselleştirme ve mekânsal analizin karara dönüştüğü en bilinen erken örnektir.

Veriyle düşünürken tuzaklar: yanlılıklar ve safsatalar

Ana kural: **korelasyon nedensellik değildir**. İki değişkenin birlikte hareket etmesi birinin diğerine neden olduğunu göstermez; çoğu zaman arkada bir **karıştırıcı (ortak neden) değişken** vardır.

Sunumdaki sahte korelasyon örnekleri

Örnek	Gerçek açıklama
Dondurma satışı ↔ köpekbalığı saldırısı	Ortak neden: **yaz / sıcak hava**
Organik gıda satışı ↔ otizm teşhisi (r = 0,997)	İkisi de zamanla artıyor; teşhis kriteri ve farkındalık değişti. Ortak trend ≠ neden
Kişi başı çikolata ↔ Nobel sayısı (r = 0,79)	Ülkenin refahı, eğitim ve araştırma yatırımı
2016 Brexit "ayrıl" bölgeleri ↔ 1992 deli dana (BSE) bölgeleri	Harita benzerliği nedensellik değildir (ekolojik düzeyde çıkarım tehlikesi)
Çatıdaki leylek yuvası ↔ çocuk sayısı	Büyük evde hem daha çok çocuk hem daha çok yuva yeri var

Datasaurus: önce görselleştir

Farklı şekilli veri setleri (dinozor dahil) **aynı ortalama, standart sapma ve korelasyona** sahip olabilir. Yalnız özet istatistiğe bakmak yanıltır; veriyi mutlaka **grafikle** incele. **Anscombe dörtlüsü** de aynı dersi verir.

1. Örneklem ve seçim yanlılıkları

Terim	Kısaca
Hayatta kalma yanılgısı (Survivorship bias)	Yalnızca başaranlara/hayatta kalanlara bakmak (Wald'ın uçakları)
Cımbızlama (Cherry picking)	İşine gelen veriyi seçip diğerlerini yok saymak
Gönüllü katılım yanlılığı	Ankete yalnızca güçlü fikri olanlar katılır; örneklem temsilî olmaz

2. İstatistiksel ve metodolojik çarpıtmalar

Terim	Kısaca
Teksas keskin nişancısı	Önce ateş edip hedefi kurşunların etrafına çizmek; rastgele kümelenmeye sonradan anlam yüklemek
Simpson paradoksu	Alt gruplardaki eğilimin gruplar birleşince **tersine dönmesi**
Sahte hassasiyet	Kaba tahmini "%37,284" gibi aşırı kesin göstermek
Ortalamanın aldatıcılığı	Ortalamaya göre plan yapmak; "ortalama kişi" çoğu zaman yoktur
Göreceli vs mutlak risk	"Riski %50 artırıyor" (1/10.000 → 1,5/10.000) diyerek algıyı abartmak

3. Mantıksal ve çıkarımsal safsatalar

Terim	Kısaca
Cum hoc ergo propter hoc	**Birlikte** olduğu için biri diğerinin nedeni sanmak
Post hoc ergo propter hoc	**Ondan sonra** olduğu için onun yüzünden sanmak
Ekolojik safsata	Grup düzeyindeki bulguyu tek tek bireylere genellemek
Kumarbaz safsatası	"5 kez yazı geldi, şimdi tura gelir"; bağımsız olaylar birbirini etkilemez
Ortalamaya dönüşü görmezden gelme	Uç sonucun ardından gelen normale dönüşü bir müdahalenin etkisi sanmak

Ezber ipucu: *cum* = "ile" (birlikte) → korelasyon hatası; *post* = "sonra" → zaman sırası hatası. Dondurma–köpekbalığı sorusu gelirse cevap: **cum hoc**, karıştırıcı değişken **sıcak hava**.

EDA: 7 temel veri seti ve 12 soruluk kontrol listesi

Model kurmadan önce veriyi tanımak gerekir: boyutu, tipleri, eksikleri ve dağılımı. Derste 7 klasik veri seti ve her birine sorulacak 12 soru verildi.

7 temel veri seti

Veri seti	Tür	Boyut	Ne için
Iris	Klasik tablo / sınıflandırma	150 örnek, 4 nitelik	Çiçek türü (3 sınıf); en bilinen başlangıç seti
Wine	Klasik tablo / sınıflandırma	178 örnek, 13 nitelik	Kimyasal özelliklerden 3 şarap üreticisi
Breast Cancer	İkili sınıflandırma	569 örnek, 30 nitelik	Tümör iyi (benign) / kötü (malignant) huylu
California Housing	Regresyon	20.640 blok grubu	Medyan konut fiyatı (sürekli hedef)
Titanic	Karmaşık ve eksik veri	Yolcu profilleri	Yaş/kabin eksik; kategorik + sayısal karışık
MNIST 784	Görüntü işleme	70.000 örnek, 28×28 piksel	El yazısı rakam; 784 piksel özelliği
20 Newsgroups	Metin / NLP	Binlerce haber iletisi	Metni vektörleştirme, konu modelleme

Mantığı: Her set bir problem türünü temsil eder. Iris/Wine çok sınıflı sınıflandırma, Breast Cancer ikili sınıflandırma, California regresyon, Titanic eksik veri, MNIST görüntü, 20 Newsgroups metin. "Hangi set regresyondur?" sorusunun cevabı **California Housing**.

12 soruluk EDA kontrol listesi

#	Soru	Pandas karşılığı	İpucu
01	Kaç gözlem var?	df.shape[0] veya len(df)	Satır sayısı
02	Kaç özellik var?	df.shape[1] veya len(df.columns)	Sütun sayısı
03	Özellik isimleri neler?	list(df.columns)	Kolon başlıkları
04	Hangileri sayısal?	df.select_dtypes(include='number')	int64, float64
05	Kategorik özellik var mı?	df.select_dtypes(include=['object', 'category'])	Metinsel/sınıfsal
06	Eksik veri var mı?	df.isnull().sum()	Sütun bazlı NaN sayısı
07	Hedef değişken nedir?	y (bağımlı değişken)	Tahmin edilecek sütun
08	Hedef kaç farklı değer alıyor?	y.nunique() / y.unique()	Sınıf çeşitliliği
09	Sınıflar dengeli mi?	y.value_counts(normalize=True)	Sınıf oranları (%)
10	Değer aralıkları benzer mi?	df.describe().T[['min', 'max']]	Ölçekleme ihtiyacı
11	En yüksek korelasyonlu iki özellik?	df.corr().abs()	Değişkenler arası ilişki
12	Dikkat çeken anormallik var mı?	EDA gözlemi	Aykırı değer, sıfır yoğunluğu

Son soru: "Bu veri setinden hangi sorulara cevap vermeye çalışabiliriz?" Model kurmadan önce iş problemini formüle et: sınıflandırma, regresyon, kümeleme veya anomali tespiti.

Mantığı: 10. soru normalleştirmeye, 6. soru eksik veri stratejisine, 9. soru dengesiz sınıf problemine bağlanır. Yani EDA, 2. haftanın ön işleme kararlarının girdisidir.

2. Hafta: Veri hazırlama ve temel kavramlar

Veri hazırlama, ham veriyi analize hazır hâle getiren işlemlerin bütünüdür ve analistin zamanının **yaklaşık %80'ini** alır.

- **Amaç:** Ham veriyi değersizleştiren hata ve sorunları ortadan kaldırmak.
- Literatürde aşamaların adı ve sayısı yazara göre değişir; amaç hep aynıdır.
- **Neden bu kadar vakit alır?** Gerçek dünya verisi kusurludur. İnsan hatası, teknolojik kısıt ve sistem arızası veriyi **gürültülü (noisy), eksik (missing) ve tutarsız (inconsistent)** yapar.
- **Veri nereden gelir?** İnsanın oluşturduğu dosyalar, işletme VTYS'leri, standart veritabanları, otomatik kayıt araçları (RFID, barkod, karekod), uydular. Farklı kaynak = farklı yapı ve tip.

Buzdağı benzetmesi: Su üstü (görünen) = veri madenciliği ve keşif. Su altı (görünmeyen, %80) = temizleme, birleştirme, indirgeme, dönüştürme.

Hatırlatma: Sonucu zaten tahmin edilebilen bir soru için VM'nin maliyetine katlanmak mantıklı değildir.

Nesne, özellik, ölçme, ölçek

Veri seti bir tablodur: **satırlar nesne**, **sütunlar özellik**, kesiştikleri hücre o nesne için özelliğin aldığı değerdir.

Kavram	Tanım	Eş anlamlıları
Nesne	Tablodaki satırlar; gözlemler	Kayıt, gözlem, örnek (instance)
Özellik	Tablodaki sütunlar; varlıkları birbirinden ayıran değişkenler	Değişken, nitelik, öznitelik (feature)
Ölçme	Birimlerin özelliklerinin derecesini belirleyip sayısal ifade etmek	—
Ölçek	Sınıflama, sıralama, derecelendirme veya miktar belirlemenin kural ve kısıtlarını belirleyen ölçme aracı	—

Market örneği (hepsi ölçme, ölçekleri farklı):

- Ürünleri türüne göre sınıflamak → isimsel
- Çalışanları yönetimden en alt kademeye sıralamak → sıra gösteren
- Ürünün ağırlığını ölçmek → oranlı
- Aylık performansı puanlamak → sayısal ölçek

Mantığı: Değişken tipini bilmemek ciddi analiz hatası doğurur. Klasik örnek: **posta kodlarının ortalamasını almak**. Posta kodu sayıdır ama isimseldir; ortalaması anlamsızdır.

Değişken tipleri ve ölçek hiyerarşisi

Altı değişken tipi iki gruba ayrılır: kategorik (isimsel, ikili, sıra gösteren) ve sürekli/sayısal (tamsayılı, aralıklı, oranlı). Sınavın en çok soru çıkabilecek kısmı **aralıklı–oranlı ayrımıdır**.

Grup	Tip	İşlevi	İzin verilen işlemler	Mutlak sıfır	Örnekler
Kategorik	İsimsel (Nominal)	Sınıflandırma, etiketleme	Yalnızca =, ≠, sayma	Yok	Cinsiyet, ürün türü, hastalık türü, kan grubu
Kategorik	İkili (Binary)	İki olasılıklı durum	Sayma	Yok	Doğru/Yanlış, Pozitif/Negatif, 0/1
Kategorik	Sıra gösteren (Ordinal)	Derecelendirme, sıralama	=, ≠, <, >	Yok	Kıdem, unvan, mezuniyet derecesi, harf notu
Sürekli	Tamsayılı (Integer)	Kesir alamayan sayılabilir değerler	+, −, ×	Var	Satılan ekmek, koli adedi, çocuk sayısı
Sürekli	Aralıklı (Interval)	Eşit aralıklı nicel ölçüm	+, −	**Yok** (göreli sıfır)	Sıcaklık (°C), doğum yılı, rakım
Sürekli	Oranlı (Ratio)	En üst düzey nicel ölçüm	Tüm işlemler + **oranlama**	**Var** (mutlak yokluk)	Ağırlık, boy, gelir, tutar, mesafe

Her tip için kritik noktalar

- **İsimsel:** Sayıyla kodlanabilir (1, 2, 3…) ama sayılar yalnızca **etikettir**; aritmetik anlamsız.
- **İkili:** İsimselin özel hâli; yalnızca iki sonuç.
- **Sıra gösteren:** Eşitlik + sıralama içerir, isimseli kapsar. Kademeler arası mesafe **eşit değildir**: müdür–şef farkı, şef–memur farkıyla aynı değildir.
- **Aralıklı:** Farklar anlamlıdır ama sıfır **keyfidir**: 0 °C "sıcaklık yok" değildir. Bu yüzden **oran hesaplanamaz**: 20 °C, 10 °C'nin iki katı sıcak değildir.
- **Oranlı:** Sıfır her birimde aynı anlamdadır: 0 kg = 0 g = ağırlık yok. **Oranlama yapılabilir**: 10 kg, 5 kg'ın iki katıdır.

Ölçek hiyerarşisi

İsimsel (=) ⊂ Sıra gösteren (=, <, >) ⊂ Aralıklı (+, −) ⊂ Oranlı (×, ÷, oran). Her üst düzey alttakilerin tüm özelliklerini taşır.

Karar mantığı (hızlı test)

1. Sayısal işlem anlamlı mı? Hayır → kategorik.
    1. Sadece iki değer mi? Evet → **ikili**.
    2. Sıralama anlamlı mı? Evet → **sıra gösteren**; hayır → **isimsel**.
2. Evet → sayısal.
    1. Kesirsiz sayım mı (adet)? → **tamsayılı**.
    2. "Sıfır, yokluk anlamına geliyor mu?" Evet → **oranlı**; hayır → **aralıklı**.

Mantığı: "İki katı" diyebiliyor musun? 40 kg, 20 kg'ın iki katı → oranlı. 2000 yılı, 1000 yılının "iki katı zaman" değil → aralıklı. Sıcaklık neden tuzak? Kelvin'de mutlak sıfır var: 20 °C = 293 K, 10 °C = 283 K; oran ≈ 1,035, yani sadece %3,5 fark.

Hızlı örnek seti (kitaptan): Kan grubu → isimsel · Harf notu (AA, BA, BB) → sıra gösteren · Doğum yılı → aralıklı · Aylık gelir → oranlı · Sigara içiyor mu → ikili · Sınıftaki öğrenci sayısı → tamsayılı.

4 aşamalı hat ve İstasyon 1: Veri temizleme

Veri hazırlama 4 istasyonlu bir rafineri hattıdır: **Temizle → Birleştir → İndirge → Dönüştür**. Çoğu uygulamada birden fazlası birlikte kullanılır; sıra veriye göre değişebilir.

İstasyon	Amaç	Sloganı
1. Temizleme	Eksik veri, gürültü, tutarsızlık	Eksikliği gider, aykırıyı tıraşla
2. Birleştirme	Çoklu kaynağı tek veri ambarında toplamak	Şemaları düğümle, tekrarları sil
3. İndirgeme	Daha küçük ama aynı sonucu veren veri	Boyutu daralt, hacmi sıkıştır
4. Dönüştürme	Algoritmaya uygun form	Z-skor / min-maks ile kalıba sok

Veri kalitesi şu sorunların varlığıyla ölçülür: gürültü ve aykırı değerler, eksik, tutarsız ve tekrarlı veriler.

Temizleme: üç ana başlık

Temizleme, veri kalitesi problemlerinin fark edilip doğrulanmasıdır: **eksik veri, gürültülü veri, tutarsız veri**.

Eksik veri

Nedenleri: Ankette bilgi vermek istememe, yanlış anlama, veri giriş hatası, tutarsız olduğu için silinme.

Kritik uyarı: Her boş değer eksik veri değildir. Kadın çalışanların "askerlik durumu" alanının boş olması o nesne için **uygulanamaz** olmasındandır. Doldurmak hatalı bilgi üretir; "uygulanamaz" diye ayrı kategori kullan.

Strateji karar mantığı:

1. Veri büyük ve eksik oranı çok düşük mü? → **Nesneyi/özelliği ele** (en basit; enformasyon kaybı riski).
2. Algoritma eksiği kendisi tolere ediyor mu? → **Göz ardı et** (kümelemede yalnızca dolu özelliklerle benzerlik hesabı).
3. Eksik değerin tahmini mi gerekiyor? → **Tahmin ederek doldur** (imputation).

A) Elemek

- Satırı silmek: basit ve etkili; ama o satırın diğer özelliklerindeki enformasyon da gider. Birkaç eksik satır varsa uygun.
- Sütunu silmek: özellik analiz için önemli olabilir; dikkatli ol.

B) Tahmin ederek doldurmak

Yöntem	Açıklama	Değerlendirme
Elle doldurma	Eksiği tek tek bulup girmek	Eksik çok, veri büyükse uygulanamaz
Sabit değer	Tüm boşluklara "Bilinmiyor" veya 0	Basit ama algoritmayı yanıltır; **tercih edilmez**
Merkezi eğilim	Özelliğin ortalaması, medyanı veya modu	Hızlı; **varyansı düşürür**
Sınıf ortalaması	Önce eksiğin sınıfı bulunur, o sınıfın ortalaması kullanılır	Genel ortalamadan isabetli
En olası değer	Regresyon, sonuç çıkarma araçları veya karar ağacıyla tahmin	Enformasyondan **en çok yararlanan** ve **en sık kullanılan** yöntem

C) Göz ardı etmek: Birçok algoritma eksiği atlayacak şekilde ayarlanabilir. Özellik sayısı az veya eksik sayısı çok değilse sonuç hemen hemen doğrudur.

Mantığı: Sayısal sütunda ortalama/medyan, **kategorik sütunda mod** (en sık değer) kullanılır, çünkü "Ankara" ile "İzmir"in ortalaması alınamaz. Aykırı değer varsa medyan ortalamadan daha güvenlidir.

Gürültülü veri ve aykırı değerler

Gürültü: Beklenen değerlerden sapan aykırı değerler veya hatalar. **Nedenleri:** hatalı toplama gereçleri, veri giriş/iletim problemleri, teknolojik kısıtlar, özellik isimlerindeki tutarsızlık.

#	Yöntem	Nasıl çalışır
1	Bölmeleme (Binning)	Sırala → eşit bölmelere ayır → bölme ortalaması (veya medyan/sınır) ile düzleştir; komşulara baktığı için **yerel düzleştirme**
2	Kümeleme (Clustering)	Benzer veriyi kümele; **hiçbir kümeye girmeyen** nokta aykırıdır
3	İnsan–bilgisayar denetimi	Bilgisayar şüpheliyi işaretler, insan karar verir (el yazısı tanımada faydalı mı çöp mü)
4	Regresyon	Veriyi bir fonksiyona (doğruya) uydurup pürüzleri giderir

Bölmeleme örneği (2. hafta): 4, 8, 15, 21, 21, 24, 25, 28, 34 → 3 bölme

Bölme	Değerler	Ortalama	Düzeltilmiş
1	4, 8, 15	27 / 3 = 9	9, 9, 9
2	21, 21, 24	66 / 3 = 22	22, 22, 22
3	25, 28, 34	87 / 3 = 29	29, 29, 29

Tutarsız veri

- Bazıları **kaynak belgelere** bakılarak elle düzeltilir.
- Bilgi mühendisliği araçları bilinen veri kısıtlarını ihlal eden kayıtları bulur; özellikler arası **işlevsel bağımlılıklar** ("posta kodu → şehir") hataları ortaya çıkarır.
- Örnek: doğum tarihi 2010, yaş 45 → tutarsız kayıt.

İstasyon 2: Veri birleştirme

Veri birleştirme, çoklu kaynaklardan (veritabanları, veri küpleri, dış dosyalar) gelen verinin uygun bir **veri ambarında** toplanmasıdır. Üç temel sorun ve üç çözüm ezberlenmeli.

Problem	Açıklama	Çözüm
Şema uyuşmazlığı	Aynı varlık farklı kaynakta farklı isimde (musteri_id ↔ cust_no)	**Meta veri** (veri hakkında veri) ve veri sözlükleriyle eşleştirme
Veri fazlalığı (Redundancy)	Aynı özellik birden fazla kaynaktan gelip tekrarlanmış ("yıllık gelir" ile "aylık gelir × 12")	**Korelasyon analizi**: ilişkinin yönü, büyüklüğü, önemi ölçülerek tekrarlar bulunur
Veri değer karmaşası	Ölçek, birim, gösterim farkı (kg ↔ libre; E/K ↔ 0/1)	**Birim dönüşümü ve heterojenlik düzeltmesi**: tek standarda indirgeme

Lab'deki karşılıkları (Pestil & Köme):

- **Şema eşleştirme (schema matching):** A dosyasının Türkçe sütunları ile B'nin İngilizce sütunları, B'nin metadata sayfasıyla eşlenir.
- **Varlık eşleştirme (entity resolution):** Aynı müşteri iki kanalda farklı müşteri numarasıyla olabilir. Aynı ad-soyadlı farklı kişilere dikkat.
- **Değer karmaşası:** Para birimi, ağırlık birimi, puan ölçeği, sıcaklık birimi, cinsiyet ve üyelik kodlaması farkları.

Mantığı: Şema = "sütun adları uyuşmuyor", fazlalık = "aynı bilgi iki kez var", değer karmaşası = "aynı bilgi farklı birimde". Fazlalığı korelasyonla bulursun, çünkü birinden türetilen sütun diğeriyle neredeyse 1,0 korelasyon verir.

İstasyon 3: Veri indirgeme

Çok büyük veriyi olduğu gibi analiz etmek pratik değildir; daha küçük bir veri kümesi oluşturulur. **Altın kural:** indirgenmiş veriyle elde edilen sonuç, tam veriyle elde edilecek sonuçtan **çok farklı olmamalıdır**.

Yöntem	Ne yapar	Örnek / teknik
Veri küpü birleştirme (OLAP)	Ayrıntılı veriyi üst düzeyde özetler (ön hesaplama)	Günlük/aylık satışları yıllığa çevirmek (roll-up)
Boyut indirgeme	Gereksiz/ilgisiz **sütunları** çıkarır	İleriye seçme, geriye eleme, birleşik; wrapper veya filter
Veri sıkıştırma	Kodlama/dönüşümle sıkıştırılmış gösterim	Kayıpsız / kayıplı
Büyük sayıların indirgenmesi	Veriyi daha küçük gösterimle temsil eder	Parametrik: regresyon, log-doğrusal · Parametrik olmayan: histogram, kümeleme, örnekleme

Boyut indirgeme

Faydaları: Algoritma verimli çalışır, model anlaşılır olur, görselleştirme kolaylaşır, işlemci süresi ve bellek azalır.

Sorun: d özellik varsa olası alt küme sayısı 2^d. 30 özellik → $2^{30} \approx$ 1 milyardan fazla; 20 özellik → 2^{20} = 1.048.576. Hepsini denemek imkânsız, bu yüzden **sezgisel (heuristic)** yöntemler kullanılır.

Sezgisel yöntem	Mantık
İleriye doğru seçme	Boş kümeyle başla, her adımda en iyi özelliği **ekle**
Geriye doğru eleme	Tüm özelliklerle başla, her adımda en kötüsünü **çıkar**
Birleşik	Her adımda en iyiyi ekle, en kötüyü çıkar

En iyi/en kötü özellik; istatistiksel anlamlılık testleri (özellikler bağımsız varsayımıyla) veya karar ağaçlarındaki **enformasyon kazancı (information gain)** ile belirlenir.

	Sarmalama (Wrapper)	Süzme (Filter)
Özellik seçerken	Madencilik algoritmasının **kendisini** kullanır	Algoritmadan **bağımsız** ölçüt
Sonuç geçerliliği	Daha yüksek	Daha düşük
Hesaplama maliyeti	**Çok yüksek**	Düşük

Mantığı: Wrapper, kıyafeti üstünde deneyerek seçmek (doğru ama yavaş); filter, etiketteki bedene bakarak seçmek (hızlı ama bazen uymaz).

Veri sıkıştırma

- **Kayıpsız (lossless):** Orijinal veri birebir geri elde edilir (ZIP, gzip, Parquet).
- **Kayıplı (lossy):** Yalnızca yaklaşık hâli elde edilir (JPEG, MP3).

Büyük sayıların indirgenmesi (numerosity reduction)

- **Parametrik:** Verinin kendisi değil yalnızca **model parametreleri** saklanır.
  - Doğrusal regresyon: y = a + bx → yalnızca a ve b saklanır.
  - Çoklu regresyon: birden fazla özellikle modeller.
  - Log-doğrusal model: kesikli çok boyutlu olasılık dağılımlarını yaklaşık modeller.
- **Parametrik olmayan:**
  - **Histogram** (en yaygın): veriyi aralıklara bölüp dağılımı çıkarır (eşit genişlik veya eşit frekans).
  - **Kümeleme:** veriyi kümeler ve küme temsilcileriyle ifade eder.
  - **Örnekleme:** büyük kümeyi çok daha küçük bir alt kümeyle temsil eder (basit rastgele, tabakalı).

Mantığı: Parametrik = "veriyi bir formüle sığdır, formülü sakla". Parametrik olmayan = "formül yok, özet tut". Tabakalı örnekleme, her alt grubu (ör. her ilçeyi) oranında temsil ettiği için basit rastgeleden daha dengeli sonuç verir.

İstasyon 4: Veri dönüştürme ve normalleştirme

Orijinal özellikler gerekli enformasyonu içerse de algoritmaya uygun formda olmayabilir; dönüştürme bunu düzeltir. Sınavda büyük olasılıkla **min-maks, z-skor ve ondalık ölçekleme hesabı** sorulur.

Beş dönüştürme işlemi

İşlem	Açıklama	Örnek
Düzeltme (Smoothing)	Gürültüyü temizlemek	Bölmeleme, regresyon, kümeleme
Bir araya getirme (Aggregation)	Özetleme	Günlük veriyi aylığa çevirmek
Genelleme (Generalization)	Düşük düzey veriyi üst kavrama taşımak	Yaş → genç/orta yaşlı/yaşlı · Cadde → şehir → ülke
Normalleştirme (Normalization)	Sayısal değerleri küçük aralığa ölçeklemek	Min-maks, z-skor, ondalık
Özellik oluşturma (Feature construction)	Mevcut özelliklerden yeni özellik türetmek	Yükseklik × genişlik → alan

Karıştırma: VM'deki "normalleştirme", istatistikteki değişkeni **normal dağılıma** dönüştürme değildir; amaç yalnızca **ölçeklemektir**.

Neden gerekli? Yapay sinir ağlarında öğrenmeyi hızlandırır. Mesafeye dayalı algoritmalarda (kümeleme, k-NN) zorunluya yakındır; yoksa aralığı büyük olan özellik (maaş 15.000–80.000) küçüğü (yaş 20–65) ezer.

Üç yöntemin formülleri

Min-Maks (Enk-Enb) → çıktı [0, 1]

$$X^{*} = \frac{X - X_{enk}}{X_{enb} - X_{enk}}$$

Z-Skor → ortalama 0, std 1; değerler çoğunlukla −3 ile +3 arası

$$X^{*} = \frac{X - \bar{X}}{s}, \qquad s = \sqrt{\frac{\sum (X - \bar{X})^{2}}{n - 1}}$$

Ondalık ölçekleme → çıktı (−1, +1); j, max|X*| < 1 yapan en küçük tam sayı

$$X^{*} = \frac{X}{10^{j}}$$

Mantığı:

- **Min-maks:** "Bu değer, en küçükten en büyüğe giden yolun yüzde kaçında?" En küçük 0, en büyük 1 olur.
- **Z-skor:** "Bu değer ortalamadan kaç standart sapma uzakta?" Negatif = ortalamanın altı.
- **Ondalık:** "Virgülü, en büyük sayının basamak sayısı kadar sola kaydır." 472 → 3 basamak → 1000'e böl.

Çözümlü örnek: X = 251, 148, 166, 244, 472, 356, 379

Min-maks: X_enk = 148, X_enb = 472 → payda = 472 − 148 = 324

X	Hesap	X*
251	103 / 324	0,318
148	0 / 324	0
166	18 / 324	0,056
244	96 / 324	0,296
472	324 / 324	1
356	208 / 324	0,642
379	231 / 324	0,713

Z-skor, adım 1 — ortalama: 2016 / 7 = **288**

Adım 2 — standart sapma (örneklem, n − 1):

X	X − X̄	(X − X̄)²
251	−37	1.369
148	−140	19.600
166	−122	14.884
244	−44	1.936
472	184	33.856
356	68	4.624
379	91	8.281
Toplam	0	84.550

s = √(84.550 / 6) = √14.091,67 ≈ **118,71**

Adım 3 — dönüştür:

X	Hesap	X*
251	−37 / 118,71	−0,312
148	−140 / 118,71	−1,179
166	−122 / 118,71	−1,028
244	−44 / 118,71	−0,371
472	184 / 118,71	1,550
356	68 / 118,71	0,573
379	91 / 118,71	0,767

Yorum: 148, ortalamanın 1,18 std **altında**; 472, 1,55 std **üstünde**. Kontrol: X − X̄ sütununun toplamı her zaman 0 çıkar;

çıkmıyorsa ortalamayı yanlış hesaplamışsındır.

Ondalık: En büyük mutlak değer 472 → 3 basamak → j = 3 → hepsi 1000'e bölünür: 0,251 · 0,148 · 0,166 · 0,244 · 0,472 · 0,356 · 0,379. Negatifte de çalışır: −986 ile 917 arası → j = 3 → −0,986 ile 0,917.

Üç yöntemin karşılaştırması

X	Min-maks	Z-skor	Ondalık
148	0	−1,179	0,148
166	0,056	−1,028	0,166
244	0,296	−0,371	0,244
251	0,318	−0,312	0,251
356	0,642	0,573	0,356
379	0,713	0,767	0,379
472	1	1,550	0,472

Üçü de **doğrusal dönüşümdür**: sıralamayı ve göreli mesafeleri korur, yalnızca ölçek değişir.

Hangisi ne zaman?

Durum	Öneri
Kesin sınırlı aralık gerekiyorsa (YSA girdisi, görüntü pikseli)	Min-maks
Veride aykırı değer var veya min-maks bilinmiyorsa	Z-skor (uygulamada en çok kullanılan)
Hızlı, basit, yorumlanabilir ölçek	Ondalık ölçekleme

Min-maksın zayıflığı: Aykırı değere çok duyarlı. 472 yerine hatalı 4720 olsaydı diğer tüm değerler 0'a yığılırdı. Ayrıca yeni gelen veri eski aralığın dışındaysa sonuç [0, 1] dışına taşar.

Tekrar hatırlatma: Z-skor 0–1 arası **değildir** (kitap hatası); 379 için doğru değer **0,767** (kitapta 0,770).

Python kütüphaneleri: NumPy, Pandas, scikit-learn

NumPy hesaplar, Pandas tabloyu yönetir, scikit-learn hazır veri seti ve dönüştürücü verir. Her kodun altında **değişkenler** ve **fonksiyonlar** tablosu var.

Kütüphane	Kısaltma	Ne için
NumPy	np	Sayı dizisi, hızlı matematik
Pandas	pd	Tablo (DataFrame): okuma, temizleme, birleştirme
scikit-learn	sklearn	Veri seti yükleme, ölçekleme, eksik doldurma

scikit-learn kalıbı: fit = öğren (min/max, ortalama/std hesapla) · transform = uygula · fit_transform = ikisi birden.

1. NumPy

```
import numpy as np

X = np.array([251, 148, 166, 244, 472, 356, 379])
buyukler = X[X > 300]
X_minmax = (X - X.min()) / (X.max() - X.min())
X_z = (X - X.mean()) / X.std(ddof=1)
j = len(str(int(np.abs(X).max())))
X_ondalik = X / 10**j

M = np.array([[1, 2, 3], [4, 5, 6]])
sutun_ort = M.mean(axis=0)
satir_ort = M.mean(axis=1)
```

Değişken	Ne tutar	Sonuç
X	Ham veri dizisi (ndarray)	[251 148 … 379]
buyukler	300'den büyük elemanlar	[472 356 379]
X_minmax	Min-maks sonucu	0 … 1 arası
X_z	Z-skor sonucu (kitaptaki n−1)	−1,179 … 1,550
j	En büyük sayının basamak sayısı	3
X_ondalik	Ondalık ölçekleme sonucu	0,148 … 0,472
M	2 satır × 3 sütun matris	—
sutun_ort	Her sütunun ortalaması	[2.5 3.5 4.5]
satir_ort	Her satırın ortalaması	[2. 5.]

Fonksiyon / ifade	Ne yapar	Not
np.array(liste)	Listeyi NumPy dizisine çevirir	Toplu matematik için şart
X[X > 300]	Boolean maske: koşulu sağlayanları seçer	Döngüsüz filtre
X.min() / X.max()	En küçük / en büyük değer	—
X.mean()	Ortalama	—
X.std(ddof=1)	Standart sapma	ddof=1 → n−1 (örneklem). **Varsayılan ddof=0 → n**
np.abs(X)	Mutlak değer	Negatifler için
10**j	10 üzeri j	Ondalık ölçekleme paydası
M.mean(axis=0)	Sütun boyunca hesap	axis=0 = aşağı in
M.mean(axis=1)	Satır boyunca hesap	axis=1 = sağa git

2. Pandas: okuma ve seçme

```
import pandas as pd

df = pd.read_csv("A_dukkan_kasa_satislari.csv", sep=";", decimal=",")
df.head()
df.info()
df.describe()
secim1 = df.loc[0:4, ["urun", "tutar"]]
secim2 = df.iloc[0:5, 0:2]
pahali = df[df["tutar"] > 500]
```

Değişken	Ne tutar
df	Tüm tablo (DataFrame); satır = nesne, sütun = özellik
df["tutar"]	Tek sütun (Series)
secim1	0–4 etiketli satırlar, urun ve tutar sütunları
secim2	İlk 5 satır, ilk 2 sütun
pahali	Tutarı 500'den büyük satırlar

Fonksiyon	Ne yapar	Önemli parametre
pd.read_csv()	CSV dosyasını tabloya okur	sep=";" ayırıcı, decimal="," Türkçe ondalık
pd.read_excel()	Excel okur	sheet_name="metadata" belirli sayfa
df.head(n)	İlk n satır (varsayılan 5)	—
df.info()	Sütun tipleri + dolu değer sayısı	Eksik veriyi de gösterir
df.describe()	Sayısal sütunların min, max, ortalama, std, çeyrekleri	.T ile satır-sütun çevrilir
df.loc[satır, sütun]	**İsimle** seçim	Bitiş dahil
df.iloc[satır, sütun]	**Sıra numarasıyla** seçim (i = index)	Bitiş hariç

3. EDA kontrol listesi

```python
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True)
df = iris.frame
y = df["target"]

df.shape
df.columns.tolist()
df.select_dtypes(include="number")
df.select_dtypes(include=["object", "category"])
df.isnull().sum()
y.nunique()
y.value_counts(normalize=True)
df.describe().T[["min", "max"]]
df.corr().abs()
```

Değişken	Ne tutar
iris	Veri seti paketi (data, target, frame, feature_names)
df	Özellikler + hedef birlikte tablo
y	Hedef değişken (tahmin edilecek sütun)

Fonksiyon	EDA sorusu	Döndürür
load_iris(as_frame=True)	Veriyi yükler	as_frame=True → Pandas tablosu
df.shape	1–2: gözlem, özellik sayısı	(150, 5)
df.columns.tolist()	3: özellik isimleri	Liste
df.select_dtypes(include="number")	4: sayısal sütunlar	Alt tablo
df.select_dtypes(include=["object","category"])	5: kategorik sütunlar	Alt tablo
df.isnull().sum()	6: sütun başına eksik sayısı	Series
y.nunique()	8: hedefin farklı değer sayısı	3
y.value_counts(normalize=True)	9: sınıf dengesi	Oranlar (normalize=True → yüzde)
df.describe().T[["min","max"]]	10: aralıklar benzer mi	Min-max tablosu
df.corr().abs()	11: korelasyon	Korelasyon matrisi (mutlak)

Yükleme fonksiyonu	Veri seti	Not
load_iris / load_wine / load_breast_cancer	Iris, Wine, Breast Cancer	load_ = paketle gelir
fetch_california_housing	California Housing	fetch_ = indirilir
fetch_openml("titanic", version=1)	Titanic	OpenML'den
fetch_openml("mnist_784", version=1)	MNIST	70.000 görüntü
fetch_20newsgroups(subset="train", categories=[...])	20 Newsgroups	Metin; random_state=42 sabit karıştırma

4. Eksik veri

```python
import numpy as np
import pandas as pd
from sklearn.impute import SimpleImputer

veri = pd.DataFrame({"yas": [25, np.nan, 40, 35, np.nan],
                     "sehir": ["Ankara", "İzmir", np.nan, "Ankara", "Ankara"]})

eksik = veri.isnull().sum()
silinmis = veri.dropna()
veri["yas"] = veri["yas"].fillna(veri["yas"].median())
veri["sehir"] = veri["sehir"].fillna(veri["sehir"].mode()[0])

imp = SimpleImputer(strategy="median")
veri[["yas"]] = imp.fit_transform(veri[["yas"]])

df["kira"] = df.groupby("mahalle")["kira"].transform(lambda s: s.fillna(s.mean()))
```

Değişken	Ne tutar
veri	Eksik içeren örnek tablo
np.nan	Eksik değer işareti (Not a Number)
eksik	Sütun başına eksik sayısı (yas: 2, sehir: 1)
silinmis	Eksik satırları atılmış tablo (2 satır kalır)
imp	Medyanla dolduran araç
s	groupby içinde her grubun kira sütunu

Fonksiyon	Ne yapar	Ne zaman
isnull().sum()	Eksikleri sayar	Önce tespit
dropna()	Eksik satırı siler	Eksik az ise
fillna(değer)	Eksiği verilen değerle doldurur	—
median()	Medyan	Sayısal, aykırı değer varsa
mode()[0]	Mod (en sık değer); liste döner, ilki alınır	**Kategorik** sütun
SimpleImputer(strategy=...)	Hazır doldurucu: "mean", "median", "most_frequent", "constant"	—
groupby("mahalle")	Satırları gruba ayırır	Sınıf ortalaması
transform(f)	Her gruba f uygular, orijinal boyutta döner	Gruba göre doldurma

5. Bölmeleme ve histogram

```
X = pd.Series([4, 8, 15, 21, 21, 24, 25, 28, 34])
bolme = pd.qcut(X, q=3, labels=False)
X_duz = X.groupby(bolme).transform("mean")
araliklar = pd.cut(X, bins=3)
histogram = araliklar.value_counts().sort_index()
```

Değişken	Ne tutar	Sonuç
X	Sıralı örnek veri	—
bolme	Her elemanın bölme numarası	0,0,0,1,1,1,2,2,2
X_duz	Bölme ortalamasıyla düzeltilmiş veri	9,9,9,22,22,22,29,29,29
araliklar	Eşit genişlikte aralık etiketleri	—
histogram	Her aralıkta kaç eleman var	—

Fonksiyon	Ne yapar	Akılda kalsın
pd.qcut(X, q=3)	**Eşit frekans**: her bölmede eşit eleman	q = quantile, kalabalığı eşit böl
pd.cut(X, bins=3)	**Eşit genişlik**: aralık uzunlukları eşit	Cetvelle eşit böl
labels=False	Etiket yerine 0,1,2 numara verir	—
value_counts()	Her değerden kaç tane	Histogramın sayıları

6. Tutarsızlık ve tekrar

```
df["urun"] = df["urun"].str.strip().str.lower()
df["cinsiyet"] = df["cinsiyet"].replace({"E": "Erkek", "K": "Kadın", 1: "Erkek", 0: "Kadın"})
df["tutar"] = pd.to_numeric(df["tutar"], errors="coerce")
hatali = df[df["tutar"] != df["adet"] * df["birim_fiyat"]]
tekrar = df.duplicated().sum()
df = df.drop_duplicates()
```

Değişken	Ne tutar
hatali	tutar ≠ adet × birim fiyat olan (tutarsız) satırlar
tekrar	Tekrarlanan satır sayısı

Fonksiyon	Ne yapar
str.strip()	Baştaki/sondaki boşluğu siler ("pestil " → "pestil")
str.lower()	Küçük harfe çevirir ("PESTİL" → "pestil")
replace({eski: yeni})	Kodları tek standarda eşler (E/K, 0/1 → Erkek/Kadın)
pd.to_numeric(errors="coerce")	Metni sayıya çevirir; çevrilemeyeni NaN yapar
duplicated()	Her satır için "tekrar mı?" True/False
drop_duplicates()	Tekrarları siler

7. Birleştirme

```
B = B.rename(columns={"customer_id": "musteri_id", "amount": "tutar"})
tum = pd.concat([A, B], ignore_index=True)
tum = tum.merge(D, on="ilce", how="left")
korelasyon = tum[["tutar", "tutar_eur"]].corr()
```

Değişken	Ne tutar
A, B	Dükkan ve e-ticaret satış tabloları
D	İlçe referans tablosu (mesafe, rakım)
tum	Birleşik satış tablosu
korelasyon	İki sütunun korelasyonu; ~1,0 ise biri fazlalıktır

Fonksiyon	Ne yapar	Konu karşılığı
rename(columns={...})	Sütun adını değiştirir	Şema eşleştirme
pd.concat([A, B])	**Alt alta** ekler (satır)	Aynı yapıdaki kaynakları toplama
ignore_index=True	Satır numaralarını baştan verir	—
merge(D, on="ilce", how="left")	**Yan yana** ekler (sütun), SQL JOIN	Referans bilgisi ekleme
how="left"	Sol tablonun tüm satırlarını korur	—
corr()	Korelasyon matrisi	Veri fazlalığı tespiti

8. İndirgeme

```
kup = tum.pivot_table(index="ilce", columns="urun", values="tutar", aggfunc="sum")
yillik = tum.groupby(["yil", "ilce"])["tutar"].sum()
ornek = tum.sample(frac=0.10, random_state=42)
tabakali = tum.groupby("ilce").sample(frac=0.10, random_state=42)
tum.to_csv("temiz.csv", index=False)
tum.to_csv("temiz.csv.gz", index=False, compression="gzip")
tum.to_parquet("temiz.parquet")
```

Değişken	Ne tutar
kup	İlçe × ürün toplam satış tablosu (veri küpü)
yillik	Yıl ve ilçe bazında toplam (roll-up)
ornek	%10 basit rastgele örnek
tabakali	Her ilçeden ayrı %10 (tabakalı örnek)

Fonksiyon	Ne yapar	Parametre
pivot_table()	Çapraz özet tablo (OLAP küpü)	index=satır, columns=sütun, values=değer, aggfunc="sum"
groupby([...]).sum()	Gruplara göre toplar	Roll-up
sample(frac=0.10)	Rastgele %10 seçer	random_state=42 → her çalıştırmada aynı sonuç
groupby("ilce").sample()	Her gruptan ayrı örnek	Tabakalı örnekleme
to_csv(compression="gzip")	Sıkıştırılmış CSV yazar	Kayıpsız
to_parquet()	Sütun bazlı ikili format	Kayıpsız, genelde en küçük

9. Dönüştürme

```python
from sklearn.preprocessing import MinMaxScaler, StandardScaler

df = pd.DataFrame({"X": [251, 148, 166, 244, 472, 356, 379]})
df["minmax"] = MinMaxScaler().fit_transform(df[["X"]])
df["z_kitap"] = (df["X"] - df["X"].mean()) / df["X"].std(ddof=1)
df["z_sklearn"] = StandardScaler().fit_transform(df[["X"]])
j = int(np.ceil(np.log10(df["X"].abs().max() + 1)))
df["ondalik"] = df["X"] / 10**j

df["yas_grubu"] = pd.cut(df["yas"], bins=[0, 30, 50, 120], labels=["genç", "orta", "yaşlı"])
df["tarih"] = pd.to_datetime(df["tarih"], dayfirst=True)
df["ay"] = df["tarih"].dt.month
df["ceyrek"] = df["tarih"].dt.quarter
df["kg_basi_fiyat"] = df["tutar"] / df["agirlik_kg"]
df["gurbetci"] = (df["ulke"] != "Türkiye").astype(int)
```

Değişken	Ne tutar	472 için
minmax	Min-maks sonucu	1
z_kitap	Z-skor, n−1 (kitap)	1,550
z_sklearn	Z-skor, n (StandardScaler)	1,674
j	Basamak sayısı	3
ondalik	Ondalık ölçekleme	0,472
yas_grubu	Genelleme: yaş → kategori	—
ay, ceyrek	Tarihten türetilen parçalar	—
kg_basi_fiyat	Özellik oluşturma: tutar / kg	—
gurbetci	İkili özellik: yurt dışı = 1	—

Fonksiyon	Ne yapar	Not
MinMaxScaler()	[0, 1] ölçekler	fit min/max'ı öğrenir
StandardScaler()	Z-skor	**n'e böler** → kitaptan farklı sonuç
df[["X"]]	Tek sütunu tablo (2 boyut) olarak verir	sklearn hep 2 boyut ister; df["X"] 1 boyut
np.log10(x)	10 tabanında logaritma	ceil ile yukarı yuvarlayınca basamak sayısı
np.ceil()	Yukarı yuvarlar	2,67 → 3
pd.cut(bins, labels)	Sayıyı aralığa göre kategoriye çevirir	Genelleme / kesikleştirme
pd.to_datetime(dayfirst=True)	Metni tarihe çevirir	Türkçe gün.ay.yıl
.dt.month / .dt.quarter	Ay / çeyrek	Tarih → ay/çeyrek genellemesi
astype(int)	True/False → 1/0	İkili değişken üretir

En sık hata: std'nin bölündüğü sayı. Pandas .std() → n−1 · NumPy np.std() ve StandardScaler → n.

R (kitap): clusterSim paketi, data.Normalization(x, type="n4") = min-maks, type="n1" = z-skor.

Pestil & Köme lab senaryosu

Lab, 2. haftanın tüm teorisini tek bir kurgusal vakada uygulatıyor: üç kirli kaynaktan **tek, temiz, analize hazır veri seti** üretmek. Sınavda "bu durumda hangi işlemi yaparsın?" tipi senaryo sorusu buradan gelebilir.

Senaryo: Gümüşhane çarşısındaki kurgusal aile işletmesi pestil, köme, dut pekmezi, kuşburnu marmelatı satıyor. İki kanal: çarşı dükkanı ve e-ticaret pazaryeri. Ürünler 6 ilçeden (Merkez, Torul, Kürtün, Kelkit, Köse, Şiran) geliyor. Müşterilerin önemli kısmı İstanbul, Ankara, Kocaeli, Bursa ve Almanya'daki Gümüşhaneliler. Dönem: Ocak 2024 – Eylül 2025.

İşletmenin soruları: Hangi ilçeden, hangi üründen, hangi ayda ne kadar satıyoruz? Gurbetçi müşteriler yerel müşterilerden farklı mı? Kargo mesafesi memnuniyeti etkiliyor mu?

Dosya	Kaynak	Not
A_dukkan_kasa_satislari.csv	Dükkan kasa yazılımı	Ayırıcı ;, ondalık , (Türkçe Excel)
B_eticaret_siparisleri.xlsx	Pazaryeri dışa aktarımı	İngilizce sütunlar; metadata sayfası okunmalı
C_uretici_kayitlari.csv	Üretici/kooperatif kayıt defteri	Ayırıcı ;
D_ilce_referans_tablosu.csv	Dış kaynak	Temiz kabul edilir; düzeltmede referans

Görevler ve bağlı olduğu konu

Görev	Ne isteniyor	Bağlı konu
1. Değişken tipleri	Her sütunu 6 tipten birine ata; aralıklı/oranlı ayrımını gerekçelendir (sıcaklık, rakım, tarih ↔ ağırlık, tutar, mesafe); işe yaramayan sütunları belirle	Değişken tipleri
2. Temizleme	İmkânsız değerleri bul, gerçek-ama-sıra-dışıyı hatadan ayır; eksikliğin kaç farklı biçimde kodlandığını bul; her sütuna "göz ardı / tahmin" kararı; farklı yazımları birleştir; çelişkileri D tablosu ve kısıtlarla (yaş aralığı, tutar = adet × birim fiyat) düzelt	İstasyon 1
3. Birleştirme	A–B şema eşleştirme (metadata), B–C üretici kodu eşleştirme; varlık eşleştirme (aynı ad-soyadlı farklı kişilere dikkat); korelasyonla fazlalık; tekrar satırlar; para, ağırlık, puan, sıcaklık, cinsiyet, üyelik kodlaması farkları	İstasyon 2
4. İndirgeme	İlçe × ürün × ay küpü, yıl/çeyreğe roll-up; gereksiz özellikleri çıkar; CSV vs gzip vs Parquet boyutu; eşit genişlik ve eşit frekans histogram; %10 basit rastgele ve ilçeye göre tabakalı örnek ortalamalarını karşılaştır	İstasyon 3
5. Dönüştürme	Tutar, mesafe, rakım için min-maks, z-skor, ondalık; aykırıları temizlemeden önce/sonra min-maks farkı; ilçe → bölge, yaş → yaş grubu, tarih → ay/çeyrek/mevsim; en az 4 yeni özellik (gurbetçi, kg başı fiyat, bayram öncesi sipariş, enflasyondan arındırılmış tutar)	İstasyon 4

Teslim: Python temizleme kodu, son temiz veri seti ve her adımdaki karar ve sayıları içeren kısa rapor. Hocanın vurgusu: "Sildim" yetmez; **neyi, kaç tane, hangi kurala göre** sildiğini yaz.

Mantığı (sınav için):

- "Boş hücre tek biçim değildir": eksik veri boşluk, "NA", "-", "?", 0 veya 999 gibi farklı kodlarla gelebilir. Önce hepsini NaN'a çevir, sonra say.
- "Her aykırı değer hata değildir": Almanya'ya giden 20 kg'lık sipariş sıra dışı ama gerçek olabilir; 500 yaşında müşteri ise imkânsızdır.
- Rakım ve sıcaklık **aralıklı** (sıfırı keyfi), tutar, ağırlık ve mesafe **oranlı** (sıfır = yokluk).

Soru-cevap

Her sorunun altında cevap ve gerekçe var. 1–2. bölüm repodaki sorular, 3–5. bölüm aynı konulardan ek pratik.

1. Hafta (repodan)

S1. VM ile KDD aynı şey mi?

- Cevap: Hayır.
- Neden: KDD sürecin tamamı; VM yalnızca 3. adım (model kurma ve değerlendirme).

S2. VM'de analiz edilen veritabanının adı?

- Cevap: Veri ambarı.
- Neden: İç + dış kaynak birleştirilip temizlenir. Alt kümesi data mart, tanımları metadata.

S3. KDD'nin en uzun aşaması?

- Cevap: Veri ön işleme.
- Neden: Çöp girer, çöp çıkar; özensiz hazırlık sürekli geri dönüş yaratır.

S4. 5, 8, 15, 21, 22, 30 verisini iki bölüme ayırıp ortalama ile düzeltin.

- Cevap: 9,33 · 9,33 · 9,33 | 24,33 · 24,33 · 24,33
- Çözüm: Bölüm 1 = (5 + 8 + 15) / 3 = 28 / 3 = 9,33. Bölüm 2 = (21 + 22 + 30) / 3 = 73 / 3 = 24,33.

S5. Aynı veriyi sınır değerleriyle düzeltin.

- Cevap: 5, 5, 15 | 21, 21, 30
- Çözüm: 8 → 5'e uzaklık 3, 15'e 7 → 5 olur. 22 → 21'e uzaklık 1, 30'a 8 → 21 olur.

S6. Ön işlemede yapılan işlemler?

- Cevap: Toplama/birleştirme · Temizleme (kayıp veri, gürültü) · Yeniden yapılandırma (normalizasyon, azaltma, dönüştürme).

S7. Kümeleme ile sınıflandırma farkı?

- Cevap: Sınıflandırmada sınıflar belli (denetimli, tahmin edici). Kümelemede sınıf yok (denetimsiz, tanımlayıcı).

S8. Overfitting nedir?

- Cevap: Modelin eğitim verisini ezberlemesi.
- Neden: Kurallar eğitimde çalışır, yeni veride çöker.

S9. Geleneksel istatistik ile VM'nin farkları?

- Cevap: İstatistik hipotezle başlar, eşitliği elle kurar, sayısal veri kullanır, kirli veriyi analizde ayıklar, kolay yorumlanır.
- VM hipotezsiz ve otomatiktir, metin/ses de kullanır, temiz veriyle çalışır, uzman yorumu gerekir.

S10. Wald örneğinde DIKW katmanları?

- Veri: delik sayısı ve konumu
- Enformasyon: deliklerin yoğunluk haritası
- Bilgi: boş görünen motor/kokpit ölümcül
- Bilgelik: zırhı deliksiz hayati bölgelere ekle

S11. "Dondurma satışı artınca köpekbalığı saldırısı artıyor, dondurmayı yasaklayalım." Hata ne?

- Cevap: Cum hoc ergo propter hoc (korelasyonu nedensellik sanmak).
- Neden: Karıştırıcı değişken sıcak hava; ikisini de artırır.

S12. k-NN'de k çok büyük / çok küçük olursa?

- Büyük k: farklı noktalar aynı sınıfa toplanır.
- Küçük k: aynı sınıftakiler ayrı sınıflara düşer, gürültüye duyarlılık artar.

2. Hafta (repodan)

S1. İsimsel ile sıra gösteren farkı?

- Cevap: İkisi de kategorik. Sıra gösterende sıralama anlamlı, ama kademeler arası mesafe eşit değil.

S2. Kan grubu, harf notu, doğum yılı, aylık gelir, sigara içiyor mu, sınıftaki öğrenci sayısı?

- Cevap: İsimsel · Sıra gösteren · Aralıklı · Oranlı · İkili · Tamsayılı.
- Neden doğum yılı aralıklı: 0 yılı "zamanın yokluğu" değil.

S3. "20 °C, 10 °C'nin iki katı sıcak." Neden yanlış?

- Cevap: Celsius aralıklı; 0 °C yokluk değil, oran alınamaz.
- Kanıt: 293 K / 283 K ≈ 1,035 → yalnızca %3,5 fark.

S4. Veri hazırlamanın 4 süreci?

- Cevap: Temizleme → Birleştirme → İndirgeme → Dönüştürme.

S5. En sık kullanılan ve en güvenilir eksik veri stratejisi?

- Cevap: Regresyon / karar ağacı ile en olası değeri tahmin etmek.
- Neden: Diğer özelliklerdeki bilgiden en çok yararlanır.

S6. Kadın çalışanların boş "askerlik durumu" alanını ortalama/mod ile doldurmak doğru mu?

- Cevap: Hayır.
- Neden: Eksik değil, uygulanamaz. "Uygulanamaz" kategorisi kullanılır.

S7. Birleştirmede 3 sorun ve çözümü?

- Şema uyuşmazlığı → meta veri
- Veri fazlalığı → korelasyon analizi
- Değer karmaşası → birim dönüşümü

S8. Veri indirgeme yöntemleri?

- Cevap: Veri küpü birleştirme · Boyut indirgeme · Veri sıkıştırma · Büyük sayıların indirgenmesi.

S9. 20 özellikte kaç alt küme var? Neden sorun?

- Cevap: 2^{20} = 1.048.576.
- Neden: Hepsini denemek çok pahalı → ileriye seçme / geriye eleme gibi sezgisel yöntem.

S10. Wrapper ile filter farkı?

- Wrapper: algoritmanın kendisini kullanır; isabetli ama pahalı.
- Filter: algoritmadan bağımsız ölçüt; hızlı ama daha az isabetli.

S11. 10, 21, 14, 29, 37, 45 değerlerini z-skor ile normalleştirin.

- Cevap: −1,182 · −0,369 · −0,887 · 0,222 · 0,813 · 1,404
- Adım 1: Ortalama = 156 / 6 = 26
- Adım 2: Farklar −16, −5, −12, 3, 11, 19 → kareler 256, 25, 144, 9, 121, 361 → toplam 916
- Adım 3: s = √(916 / 5) = √183,2 ≈ 13,535
- Adım 4: Her farkı 13,535'e böl (−16 / 13,535 = −1,182)

S12. Aynı veriyi min-maks ve ondalık ölçekleme ile normalleştirin.

- Min-maks: 0 · 0,314 · 0,114 · 0,543 · 0,771 · 1 (min 10, max 45, payda 35; 21 → 11 / 35 = 0,314)
- Ondalık: 0,10 · 0,21 · 0,14 · 0,29 · 0,37 · 0,45 (en büyük 45 → 2 basamak → 100'e böl)

S13. k-NN'de yaş (20–65) ve maaş (15.000–80.000) normalleştirilmezse?

- Cevap: Mesafeyi maaş belirler, yaşın etkisi kaybolur.
- Çözüm: Normalleştirme ikisine eşit ağırlık verir.

S14. Min-maksın en önemli zayıflığı?

- Cevap: Aykırı değere duyarlı.
- Örnek: 472 yerine 4720 gelirse diğer tüm değerler 0'a yığılır. Yeni veri eski aralığın dışındaysa sonuç [0, 1] dışına taşar.

3. Ek pratik: kavram

S1. Yorumlanması en zor tahmin algoritması?

- Cevap: Yapay sinir ağları.

S2. Genetik algoritma bir VM modeli midir?

- Cevap: Hayır, eniyileme (optimizasyon) yöntemidir.

S3. Veri ambarı ile data mart farkı?

- Cevap: Ambar tüm işletmeyi kapsar; data mart tek bir bölüm/konuya yöneliktir.

S4. "Ağustos'ta İç Anadolu satışı, geçen yılla karşılaştırmalı" sorusu hangi araçla cevaplanır?

- Cevap: OLAP.
- Neden: Çok boyutlu (ürün × bölge × zaman) ama bilinen bir soru.

S5. Birliktelik kuralı ile sıra örüntü farkı?

- Birliktelik: birlikte alınanlar (bira–cips).
- Sıra örüntü: zaman sırası da var (çekiç → 3 ay içinde çivi).

S6. Alt gruplardaki eğilimin gruplar birleşince tersine dönmesine ne denir?

- Cevap: Simpson paradoksu.

S7. "5 kez yazı geldi, şimdi tura gelir" hangi safsata?

- Cevap: Kumarbaz safsatası.
- Neden: Bağımsız olaylar birbirini etkilemez.

S8. Kayıpsız ve kayıplı sıkıştırmaya birer örnek?

- Kayıpsız: ZIP, gzip, Parquet.
- Kayıplı: JPEG, MP3.

S9. Parametrik veri indirgemeye örnek?

- Cevap: Doğrusal regresyon (y = a + bx); verinin yerine yalnızca a ve b saklanır.

S10. Rakım hangi değişken tipidir?

- Cevap: Aralıklı.
- Neden: 0 m deniz seviyesi, keyfi referans; "yükseklik yok" demek değil.

S11. Hangi veri seti regresyon içindir?

- Cevap: California Housing (hedef sürekli: medyan konut fiyatı).

S12. Sabit değerle (0, "Bilinmiyor") doldurmak neden tercih edilmez?

- Cevap: Algoritmayı yanıltır; sabit, gerçek bir değerle çakışabilir.

4. Ek pratik: hesap

S1. 12, 3, 22, 9, 30, 20 verisini iki bölüme ayırıp ortalama ve sınır değerleriyle düzeltin.

- Cevap (ortalama): 8, 8, 8 | 24, 24, 24
- Cevap (sınır): 3, 12, 12 | 20, 20, 30
- Adım 1: Sırala → 3, 9, 12, 20, 22, 30
- Adım 2: Bölüm 1 = 24 / 3 = 8; Bölüm 2 = 72 / 3 = 24
- Adım 3: 9 → 3'e 6, 12'ye 3 uzak → 12. 22 → 20'ye 2, 30'a 8 uzak → 20

S2. 20, 35, 50, 80 verisini min-maks, z-skor ve ondalık ile normalleştirin.

X	20	35	50	80
Min-maks	0	0,25	0,5	1
Z-skor	−1,025	−0,439	0,146	1,317
Ondalık	0,20	0,35	0,50	0,80

- Min-maks: payda 80 − 20 = 60; 35 → 15 / 60 = 0,25
- Z-skor: ortalama 185 / 4 = 46,25; farklar −26,25, −11,25, 3,75, 33,75; kareler toplamı 1.968,75; s = √(1.968,75 / 3) ≈ 25,617; 20 → −26,25 / 25,617 = −1,025
- Ondalık: en büyük 80 → 2 basamak → 100'e böl

S3. −986 ile 917 arasındaki veri için ondalık ölçeklemede j kaçtır?

- Cevap: 3.
- Neden: Mutlak en büyük 986 → 3 basamak → sonuç −0,986 ile 0,917 arası.

5. Ek pratik: Python

S1. Eşit frekans bölmeleme fonksiyonu hangisi?

- Cevap: pd.qcut(). Eşit genişlik için pd.cut().

S2. StandardScaler ile elle hesaplanan z-skor neden farklı çıkar?

- Cevap: StandardScaler n'e, kitap (ve Pandas .std()) n−1'e böler.

S3. Kategorik sütundaki eksik hangi stratejiyle doldurulur?

- Cevap: Mod → fillna(df["s"].mode()[0]) veya SimpleImputer(strategy="most_frequent").

S4. concat ile merge farkı?

- concat: alt alta (satır) ekler.
- merge: anahtar üzerinden yan yana (sütun) ekler.

S5. Sınıf dengesini yüzde olarak gösteren komut?

- Cevap: y.value_counts(normalize=True)

S6. Türkçe Excel CSV'sini doğru okumak için iki parametre?

- Cevap: sep=";" ve decimal=","

S7. loc ile iloc farkı?

- loc: isimle (etiket) seçer.
- iloc: sıra numarasıyla seçer.

S8. MinMaxScaler'a neden df[["X"]] verilir, df["X"] değil?

- Cevap: scikit-learn 2 boyutlu tablo ister; [["X"]] tablo, ["X"] tek boyutlu Series verir.

Son tekrar listesi

- VM önceden bilinmeyeni keşfeder; KDD'nin bir adımıdır.
- KDD: Amaç → Ön işlem → Model → Yorum → İzleme. En uzun aşama ön işleme (~%80).
- Tahmin edici (regresyon, sınıflandırma) ↔ tanımlayıcı (kümeleme, birliktelik, sıra örüntü, özetleme).
- Denetimli = etiket var; denetimsiz = etiket yok.
- Korelasyon ≠ nedensellik; özet istatistikten önce görselleştir (Datasaurus, Anscombe).
- Kategorik: isimsel, ikili, sıra gösteren · Sürekli: tamsayılı, aralıklı, oranlı.
- Aralıklı ≠ oranlı: fark sıfırın "yokluk" olup olmamasıdır.
- Her boş hücre eksik veri değildir: uygulanamaz alanlara dikkat.
- Temizle → Birleştir → İndirge → Dönüştür.
- Min-maks [0, 1] · Z-skor ort. 0, std 1 (0–1 değil!) · Ondalık (−1, 1).
- k-NN, kümeleme ve YSA'da normalleştirme şart.
- Kod: Pandas .std() n−1, NumPy ve StandardScaler n; kategorik eksikte mod; load_ hazır, fetch_ indirilir.